Gestión de Datos: *Data Warehousing*

Edgar Sarmiento Calisaya

esarmientoca@unsa.edu.pe

Universidad Nacional de San Agustín – UNSA

Faculta de Ingeniería de Producción y Servicios – FIPS

Escuela de Posgrado

Maestría en Ciencia de Datos

Esta presentación adapta texto y figuras de documentos listados en la sección de referencias: bibliografía, recursos web, y diapositivas de diversos cursos de “Ciencia y Bases de Datos”

Agradecimiento a los profesores que disponibilizaron su material de aula.

Agenda

1. Introducción
2. Data Warehouse (DW)
3. Ciclo de Vida de un DW
4. Modelado Multidimensional: DW Schemas
5. On-line Analytical Processing (OLAP)
6. Data Quality
7. Data Integration
8. Extract-Transform-Load (ETL)
9. Business Intelligence
10. Data Lake (DL)

Introducción

- La gerencia del **BCP** decidió que necesitaba **mejorar la gestión de sus datos**.
- La **información** sobre **clientes**, **cuentas** y **empleados** se almacenaba en una **cantidad abrumadora de sistemas**, lo que dificultaba su **recuperación y análisis**.
- Los **datos** eran a menudo redundantes e inconsistentes, lo que limitaba su **utilidad**.
- La gerencia no podía obtener una visión global de la empresa.
- La combinación de **IBM DB2** y **SAP Business Warehouse** le otorgó al BCP capacidades integrales de **gestión de datos**.

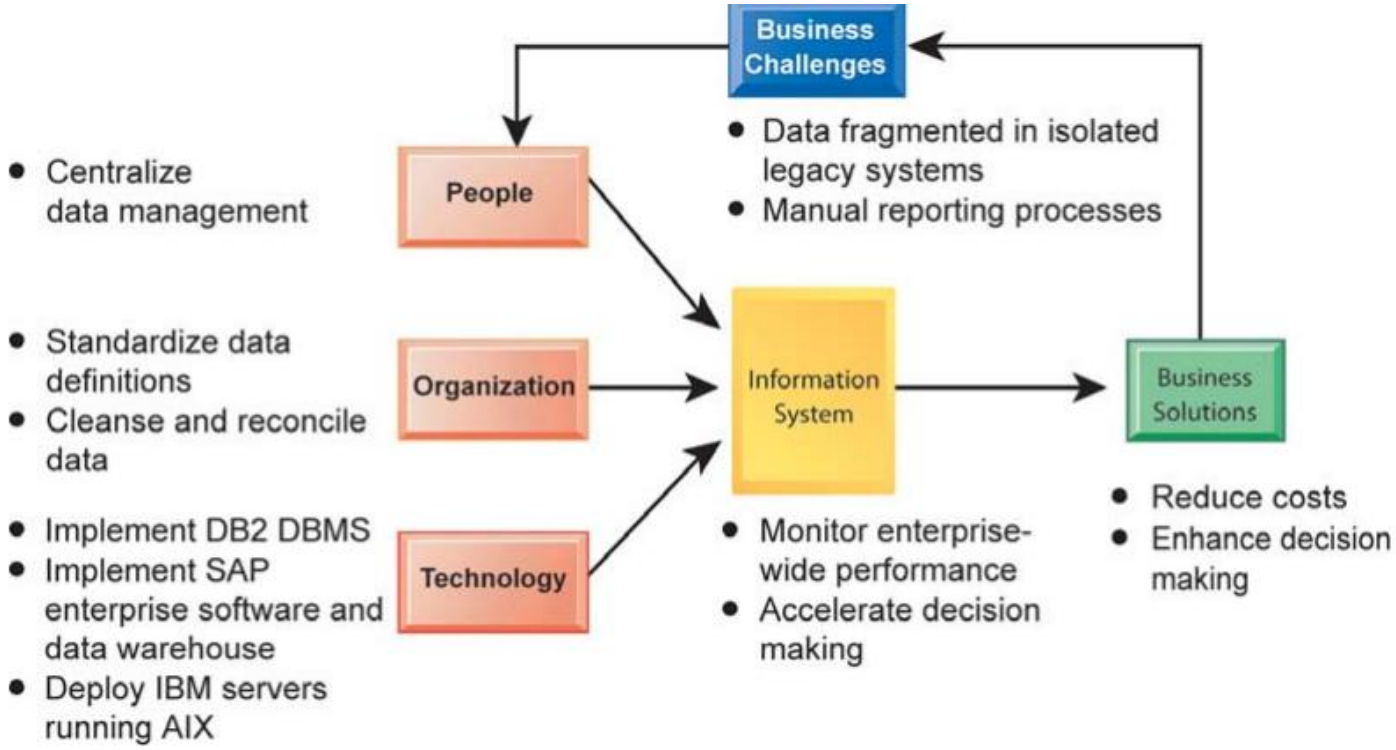

Laudon&Laudon, 2022

Fuente: IBM, "Banco de Crédito del Peru Vaults over the Competition with Help from IBM and SAP," January 20, 2011 and "Banco Credito Del Peru C," www.investing.businessweek.com, accessed April 19, 2011.

Introducción

- **Caso práctico de una empresa (Jensen et al., 2010)**
- **Ejemplo de una cadena (p. ej., tiendas de moda o concesionarios de automóviles)**
  - Cada tienda mantiene sus propios registros de clientes y ventas.
    - Preguntas difíciles de responder como: "Encuentre las ventas totales del producto X en las tiendas de Y".
  - El mismo cliente puede ser visto como clientes diferentes en diferentes tiendas; es difícil detectar información duplicada.
  - Datos imprecisos o faltantes en las direcciones de algunos clientes.
  - Los registros de compras se mantienen en el sistema de procesamiento de transacciones por un tiempo limitado (p. ej., 6 meses); luego se eliminan o archivan.
  - El mismo "producto" puede tener diferentes precios o descuentos en diferentes tiendas.

Introducción

- **Problemas en el Análisis de Datos (Jensen et al., 2010)**
  - Las bases de datos OLTP (SQL, NoSQL) son eficientes para procesamiento de transacciones, pero …
  - **COSTO DE EJECUCIÓN DE JOINS?**

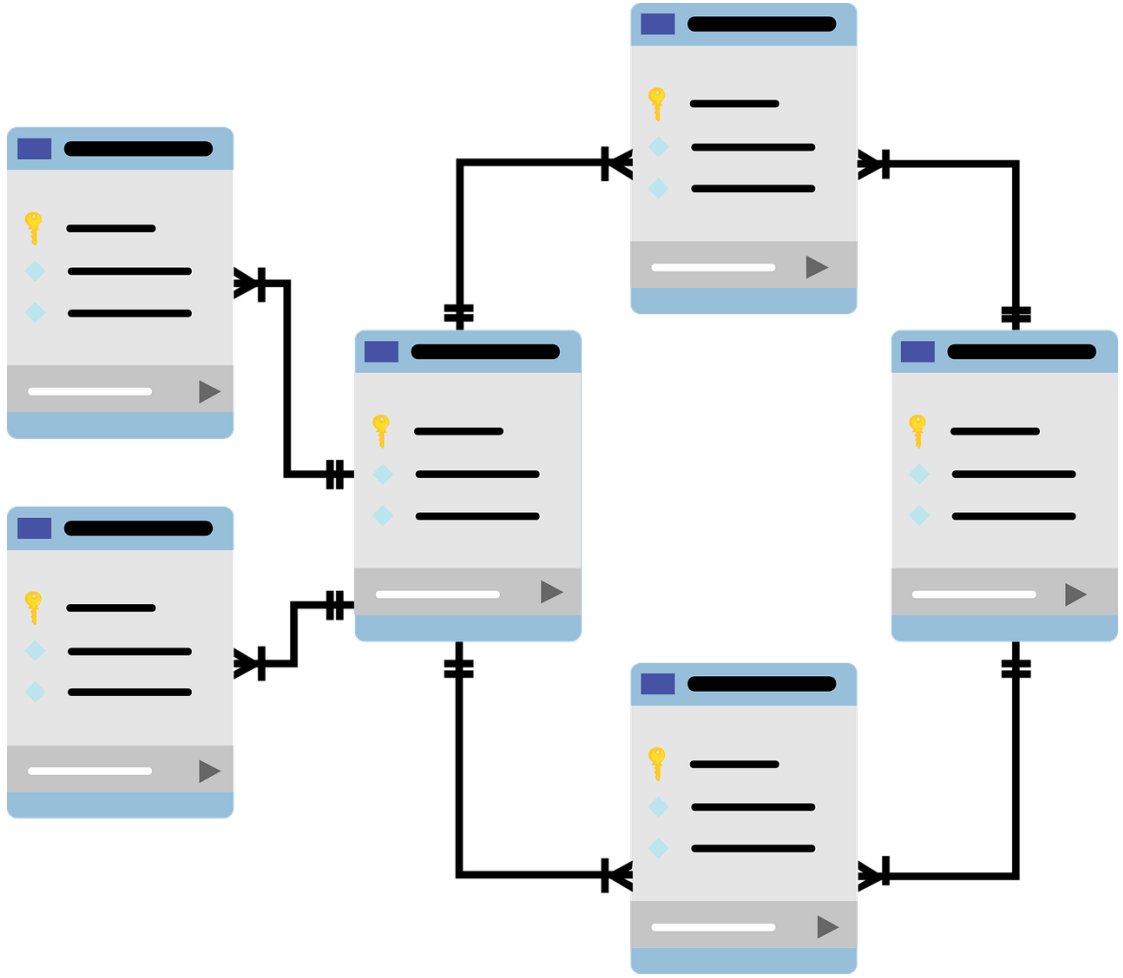

Introducción

- **Problemas en el Análisis de Datos (Jensen et al., 2010)**
  - Los **mismos datos** se encuentran en muchos **sistemas diferentes**
    - Ejemplo: datos de clientes en diferentes tiendas y departamentos
    - El mismo concepto se define de forma diferente
  - **Fuentes heterogéneas**
    - Sistemas de gestión de bases de datos relacionales, procesamiento de transacciones en línea (OLTP)
    - Datos no estructurados en archivos (p. ej., MS Word)
    - Sistemas heredados
  - Los **datos** son adecuados para **sistemas de procesamiento de transacciones**
    - Contabilidad, facturación, etc.
    - No admiten el análisis entre las funciones empresariales
  - La **calidad** de los **datos** es deficiente
    - Datos faltantes, datos imprecisos, uso diferente de los sistemas
  - Los **datos** son **volátiles**
    - Datos eliminados en sistemas operativos (6 meses)
    - Los datos cambian con el tiempo: no hay información histórica

Introducción

- **Solución para el Análisis de Datos (Jensen et al., 2010)**
  - **Nuevo entorno de análisis** donde los datos están
    - **Orientados al tema** (en lugar de orientados a la **función**)
    - **Integrados** (lógica y físicamente)
    - **Variantes temporales** (los datos siempre pueden relacionarse con el tiempo)
    - **Estables** (datos no eliminados, varias versiones)
    - Apoyo a las decisiones de gestión (organización diferente)
  - Los **datos** de los sistemas de procesamiento de transacciones son:
    - Extraídos
    - Limpiados
    - Transformados
    - Agregados (?)
    - Cargados en el nuevo entorno

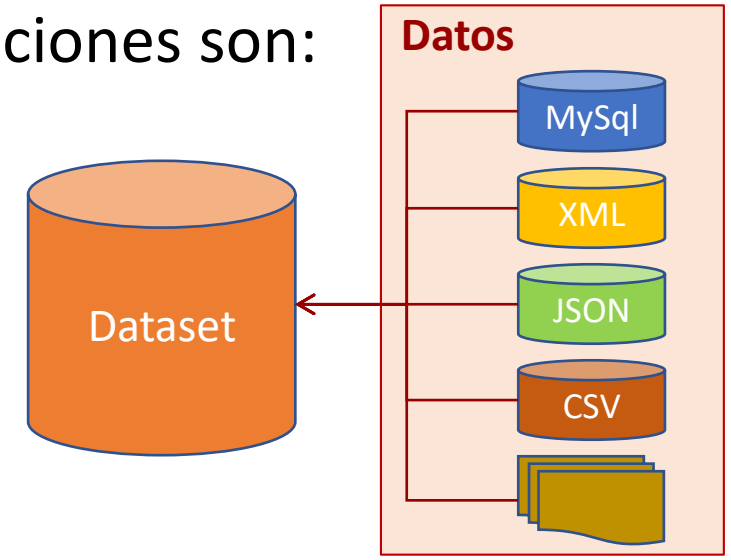

Introducción

- **Transacciones**:
  - *On-line Transaction Processing* (**OLTP**)
    - Pequeñas **transacciones** (INSERT, UPDATE, DELETE) realizadas en tiempo real y que ocurren de manera constante y rápida
    - Multiples operaciones de usuarios finales.
  - *On-line Analytical Processing* (**OLAP**)
    - Recibe **datos de OLTP** para que pueda realizar **análisis**
    - Un sistema de toma de decisiones **no realiza transacciones** (INSERTAR, ACTUALIZAR, ELIMINAR) porque su finalidad es la **consulta**.
    - Pocos usuarios – gerencia
    - Data Warehouse → Business Intelligence - BI

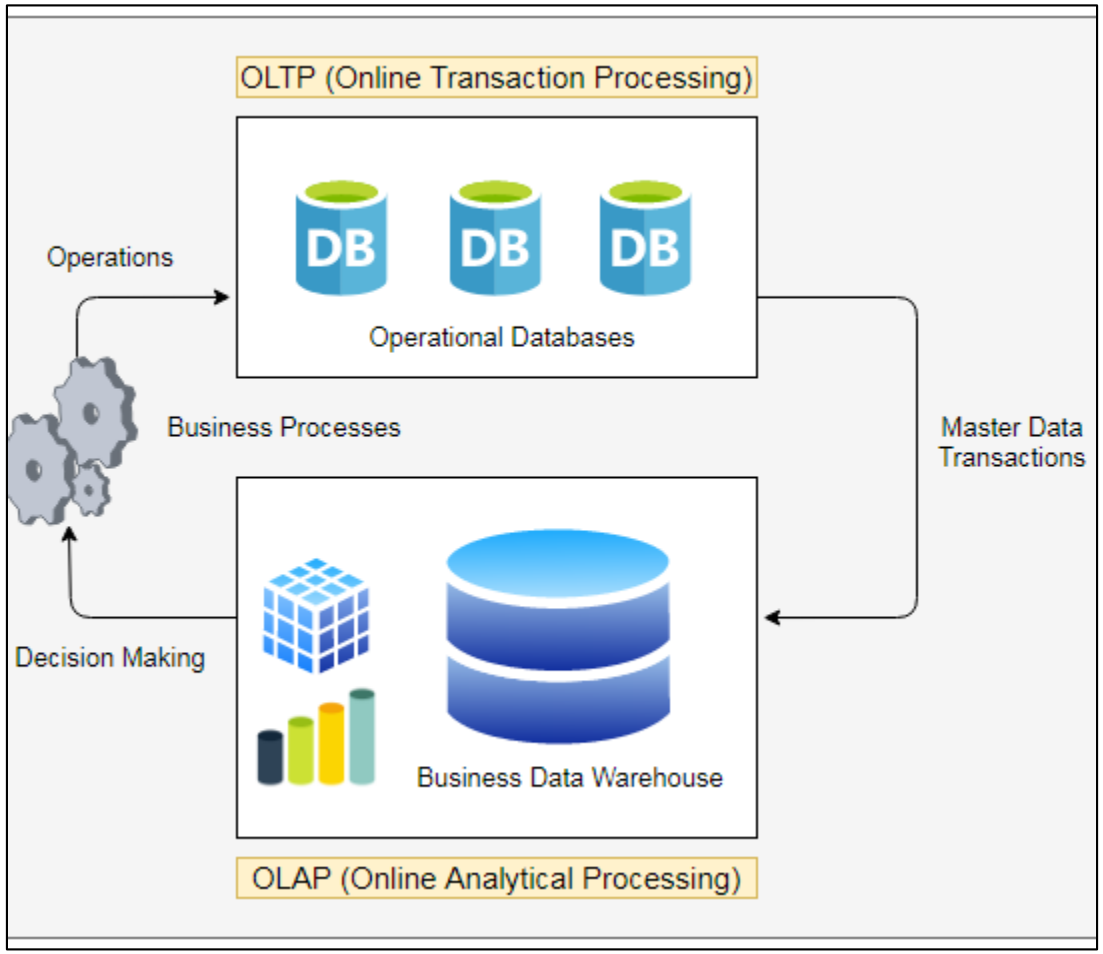

https://sqlwizardblog.wordpress.com/2020/03/15/sql-server-oltp-vs-olap

Introducción

- Actualmente las **organizaciones** tienen la preocupación de gestionar **grandes volúmenes de datos** de forma **automática**, los cuales deben ser **recolectados**, **procesados**, y **presentados** como **información útil** a los interesados con el propósito de apoyar el proceso de **toma de decisiones**.

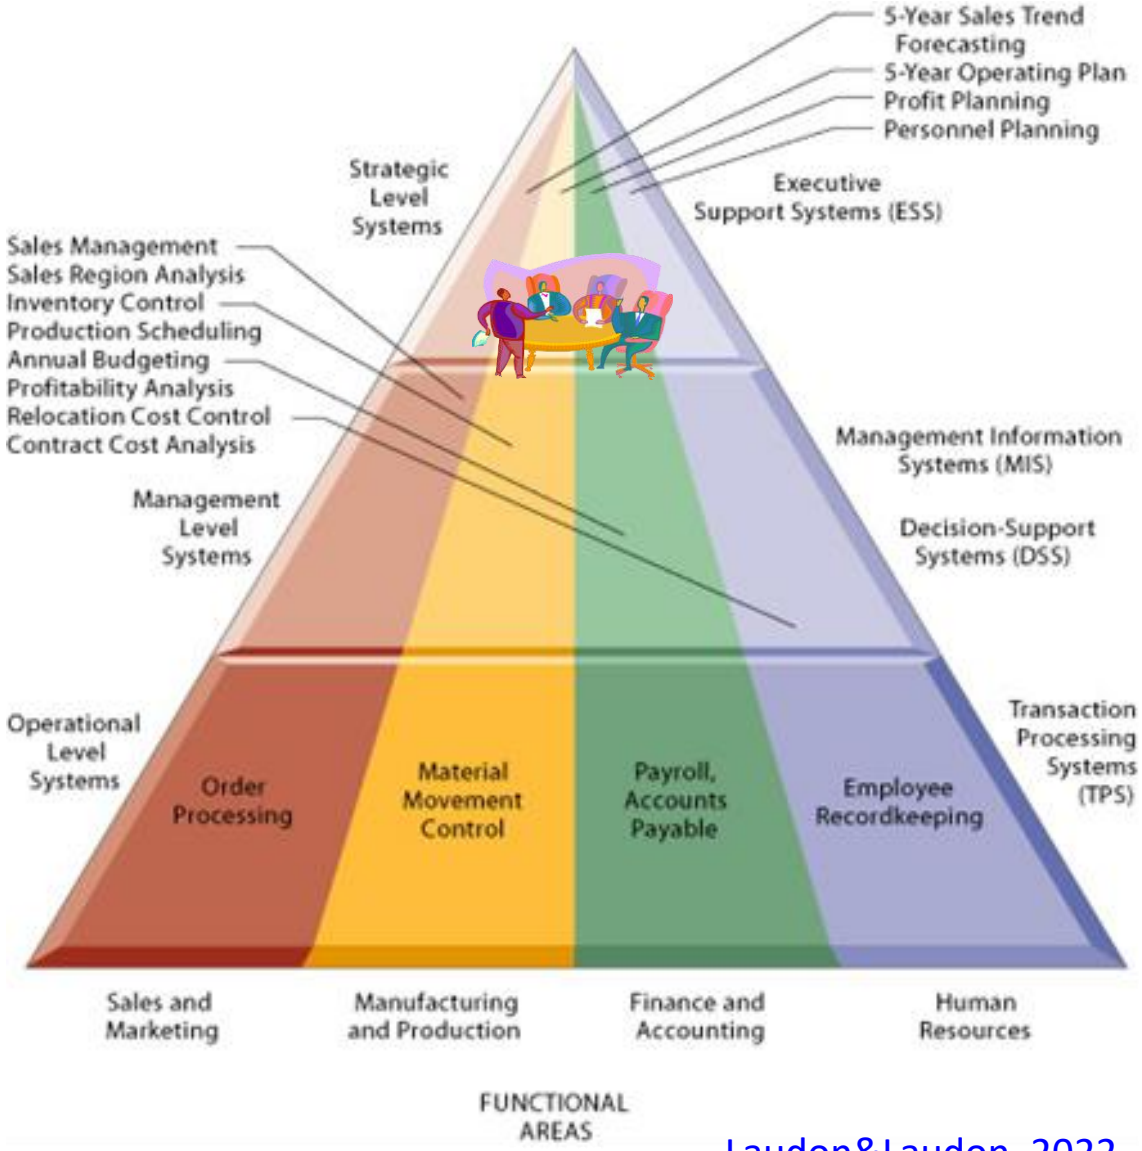

Laudon&Laudon, 2022

Introducción

Los especialistas en **Ciencia de Datos recopilan**, **almacenan**, **procesan** y **traducen datos** en **información** y **conocimiento** útil para las **organizaciones** (públicas o privadas)

- potenciando con esto la **competitividad** e **innovación** dentro de cualquier organización.

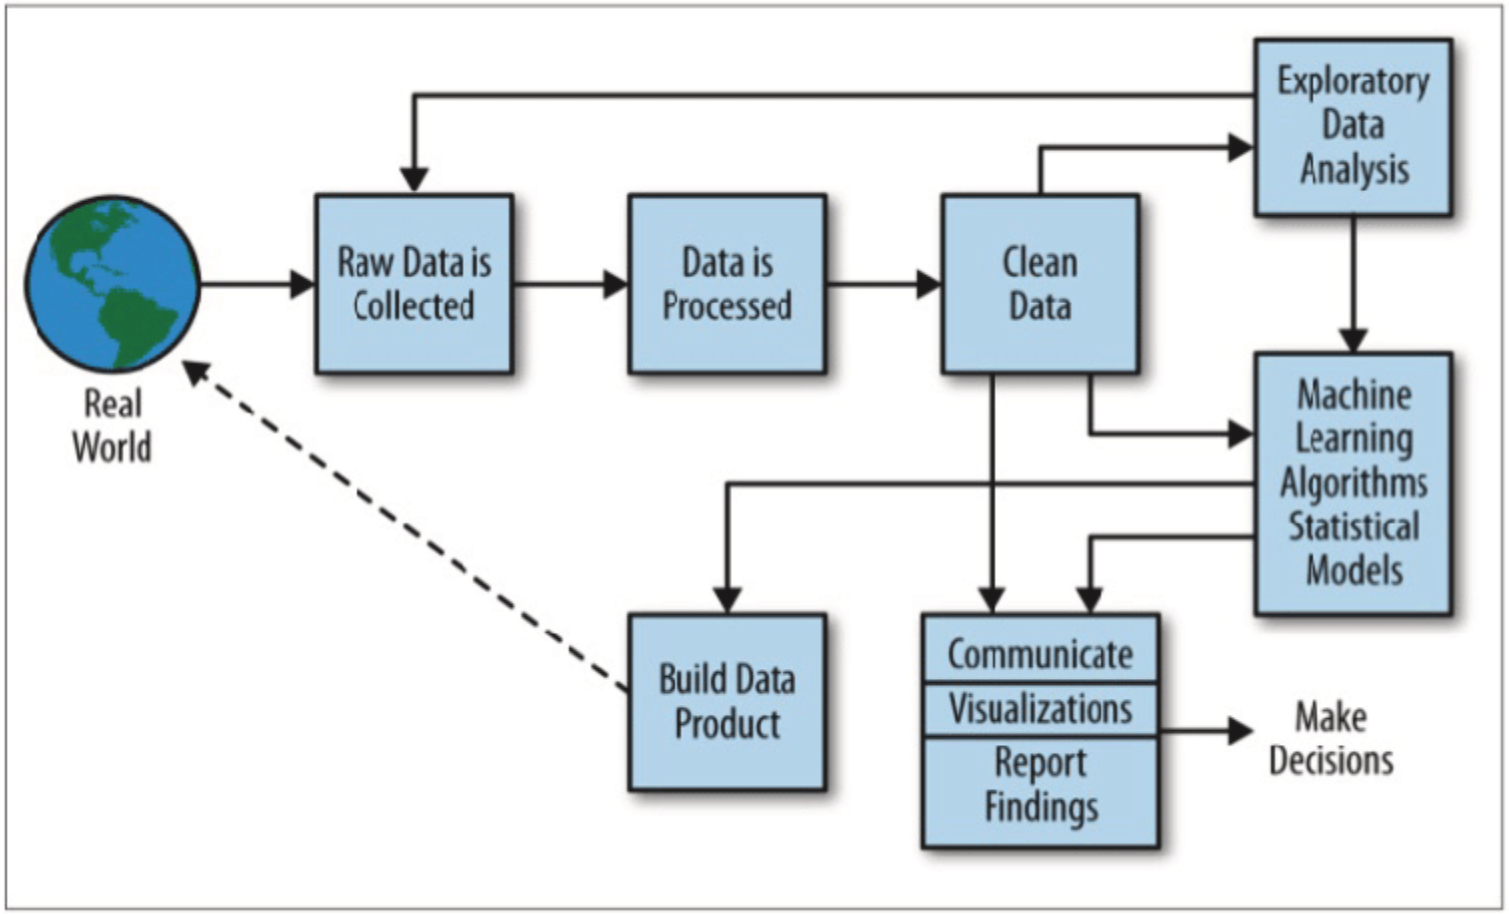

O'Neil & Schutt, 2013

Introducción

- **Minería de Datos: Proceso KDD**

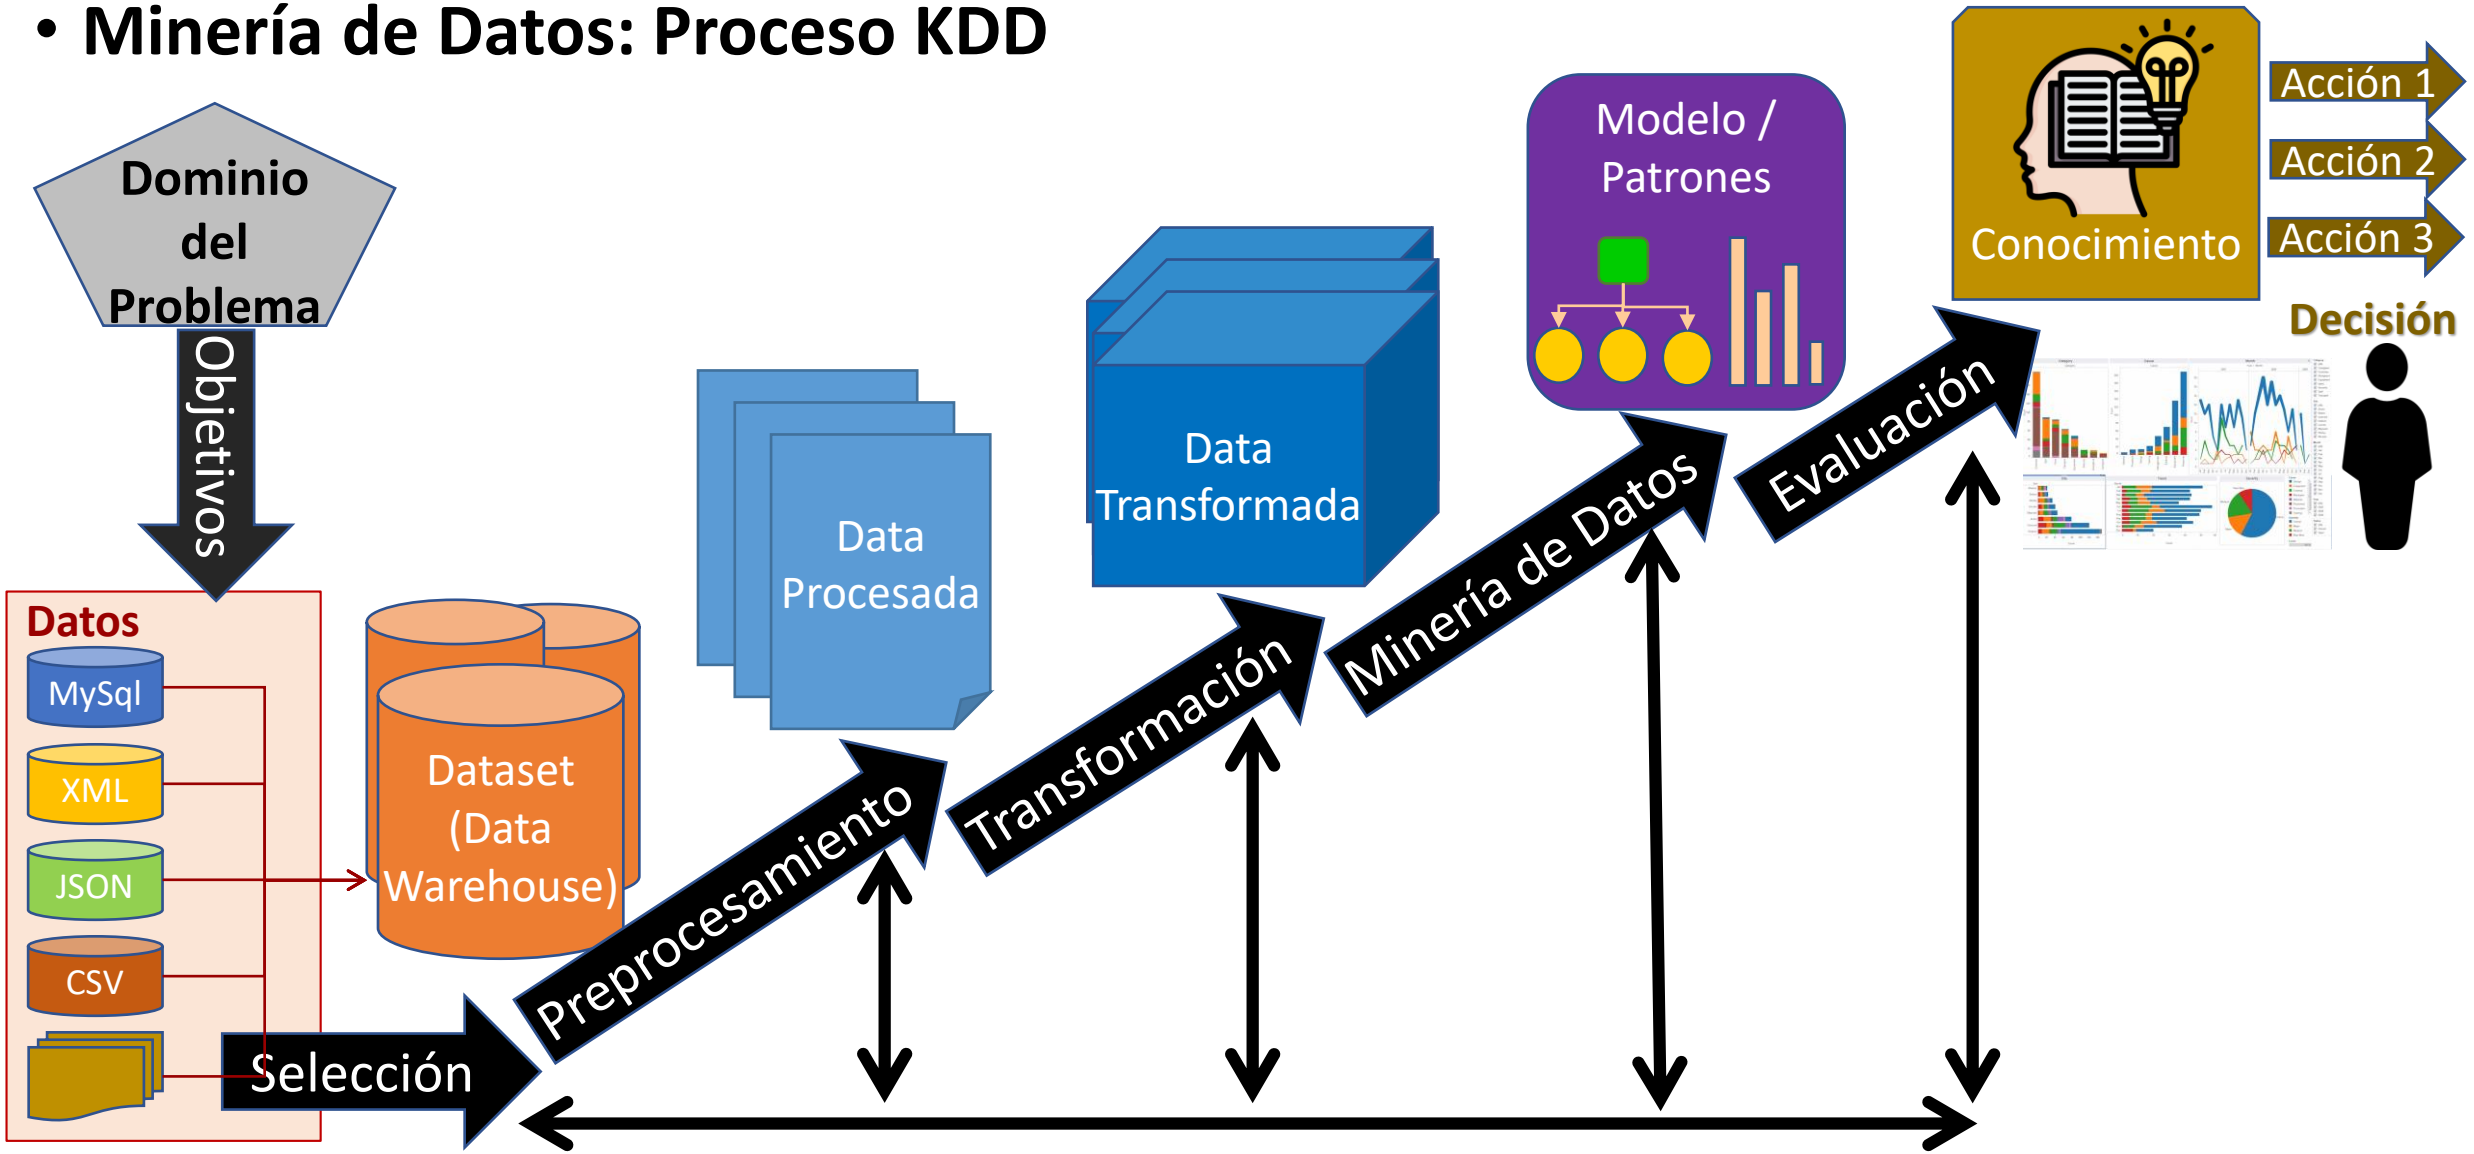

Introducción

- **Etapas de un proyecto de Ciencia de Datos** (Adaptado de O'Neil & Schutt, 2013).

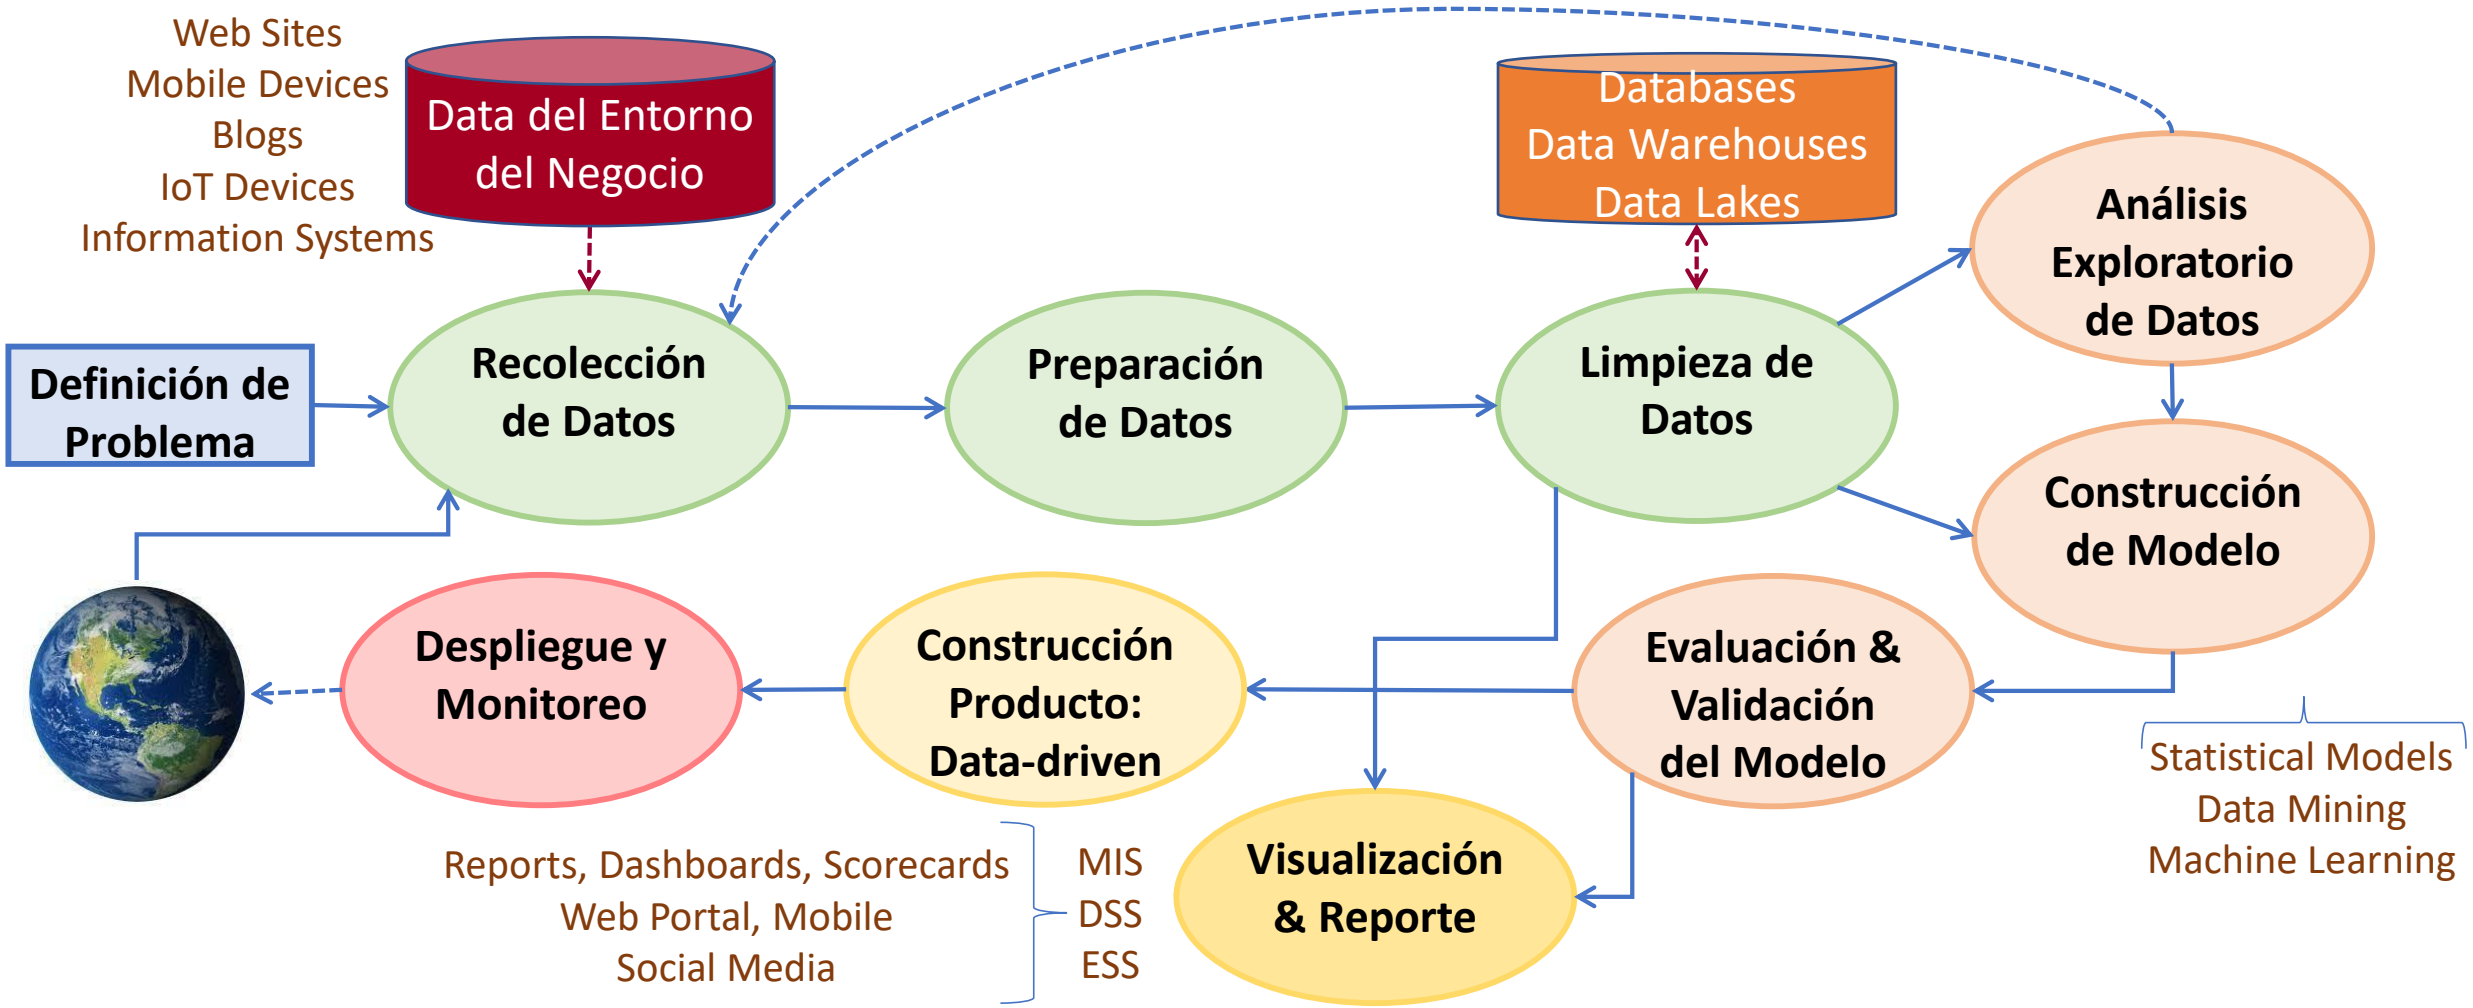

Data Warehouse

- **Un Data Warehouse (DW)** es como una **base de datos relacional** diseñada para **necesidades analíticas**.
  - Funciona con **OLAP**.
  - Es un repositorio **central** donde se almacenan **datos consolidados** de **múltiples fuentes** (bases de datos) de una **organización**:
    - Finanzas, facturación, logs del sitio web, personal, etc.
    - Diferentes modelos/formatos
  - Organizado en un **modelo de datos unificado**.
- **¿Qué es Data Warehousing?**
  - Consiste en organizar y almacenar datos de forma que su recuperación sea eficiente y precisa.
  - También se denomina proceso de **transformación de datos en información**.

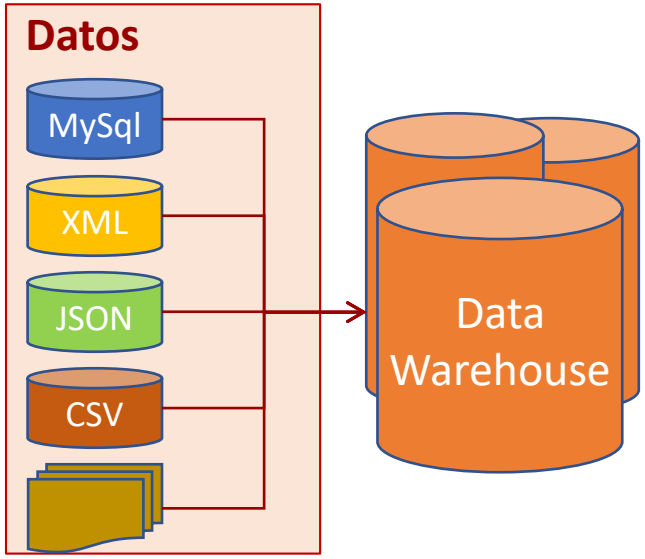

Data Warehouse

- **Objetivo:** Dar soporte al proceso de toma de decisiones
- **Análisis** avanzados fáciles de realizar
  - **Consultas Directas (SQL, OLAP), Inteligencia de Negocios (BI), Minería de Datos (DM), Machine Learning (ML), …**

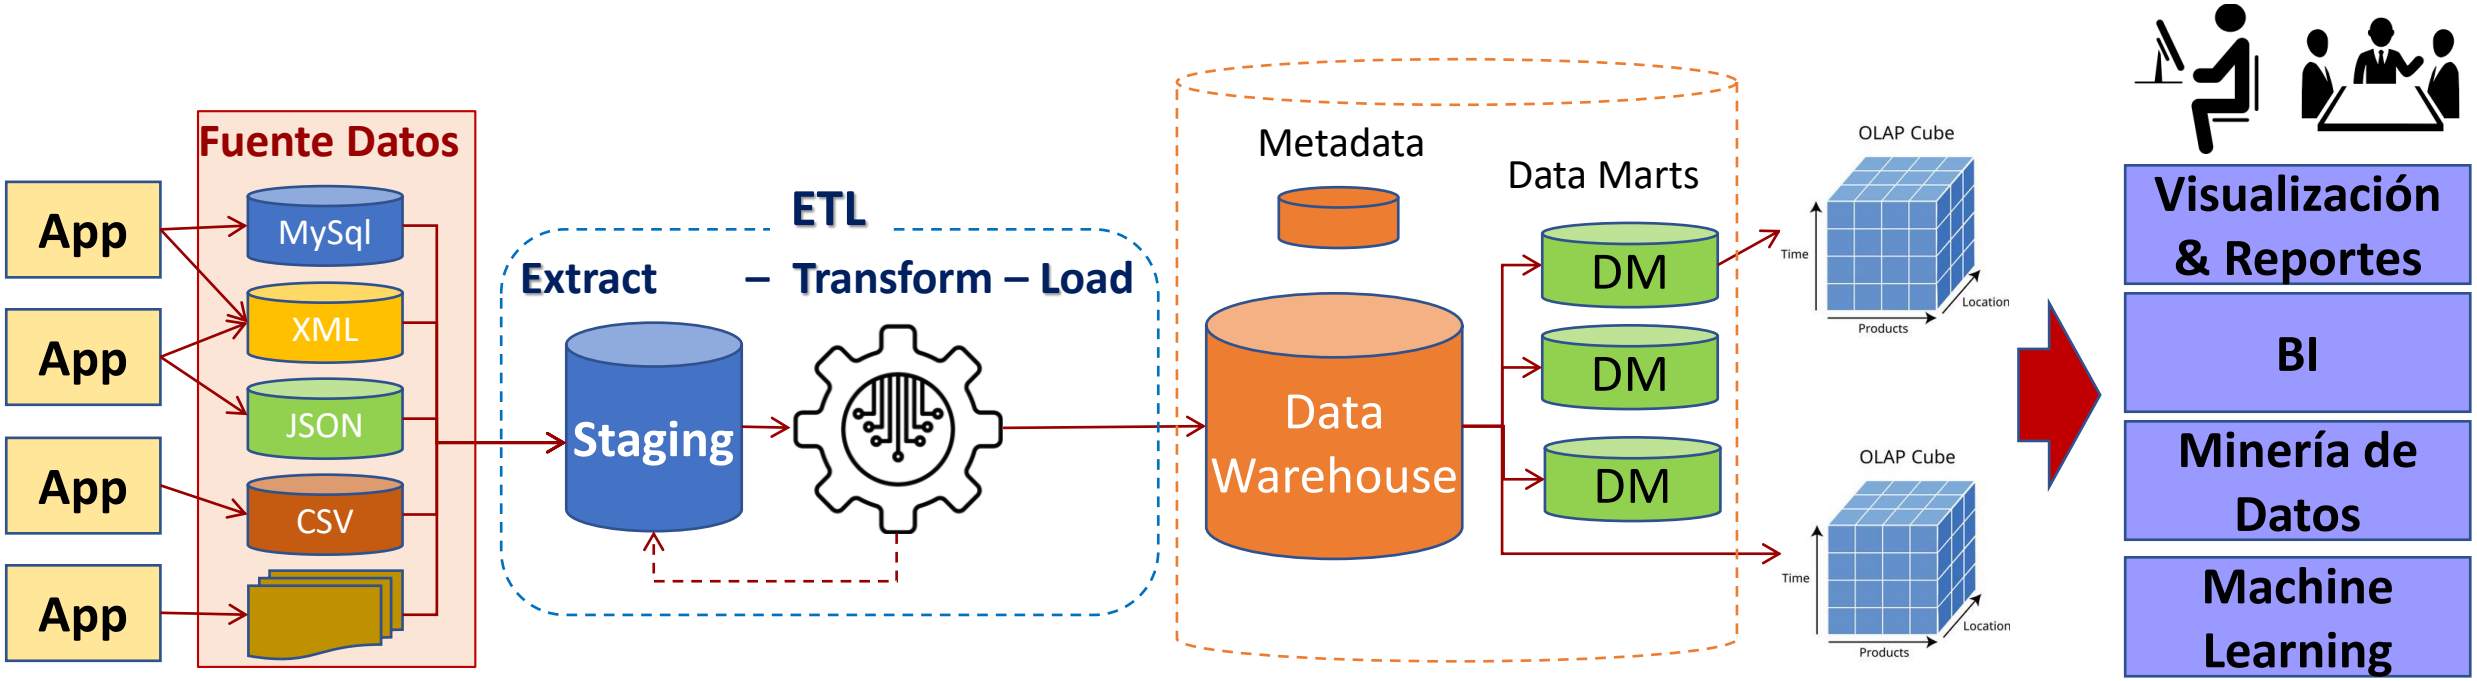

Data Warehouse

- **Características:**

Un **Data warehouse** es una colección de datos orientada a **temas**, **integrada**, **variante en el tiempo** y **no volátil** que respalda el proceso de toma de decisiones de gerencia (Inmon, 1990)

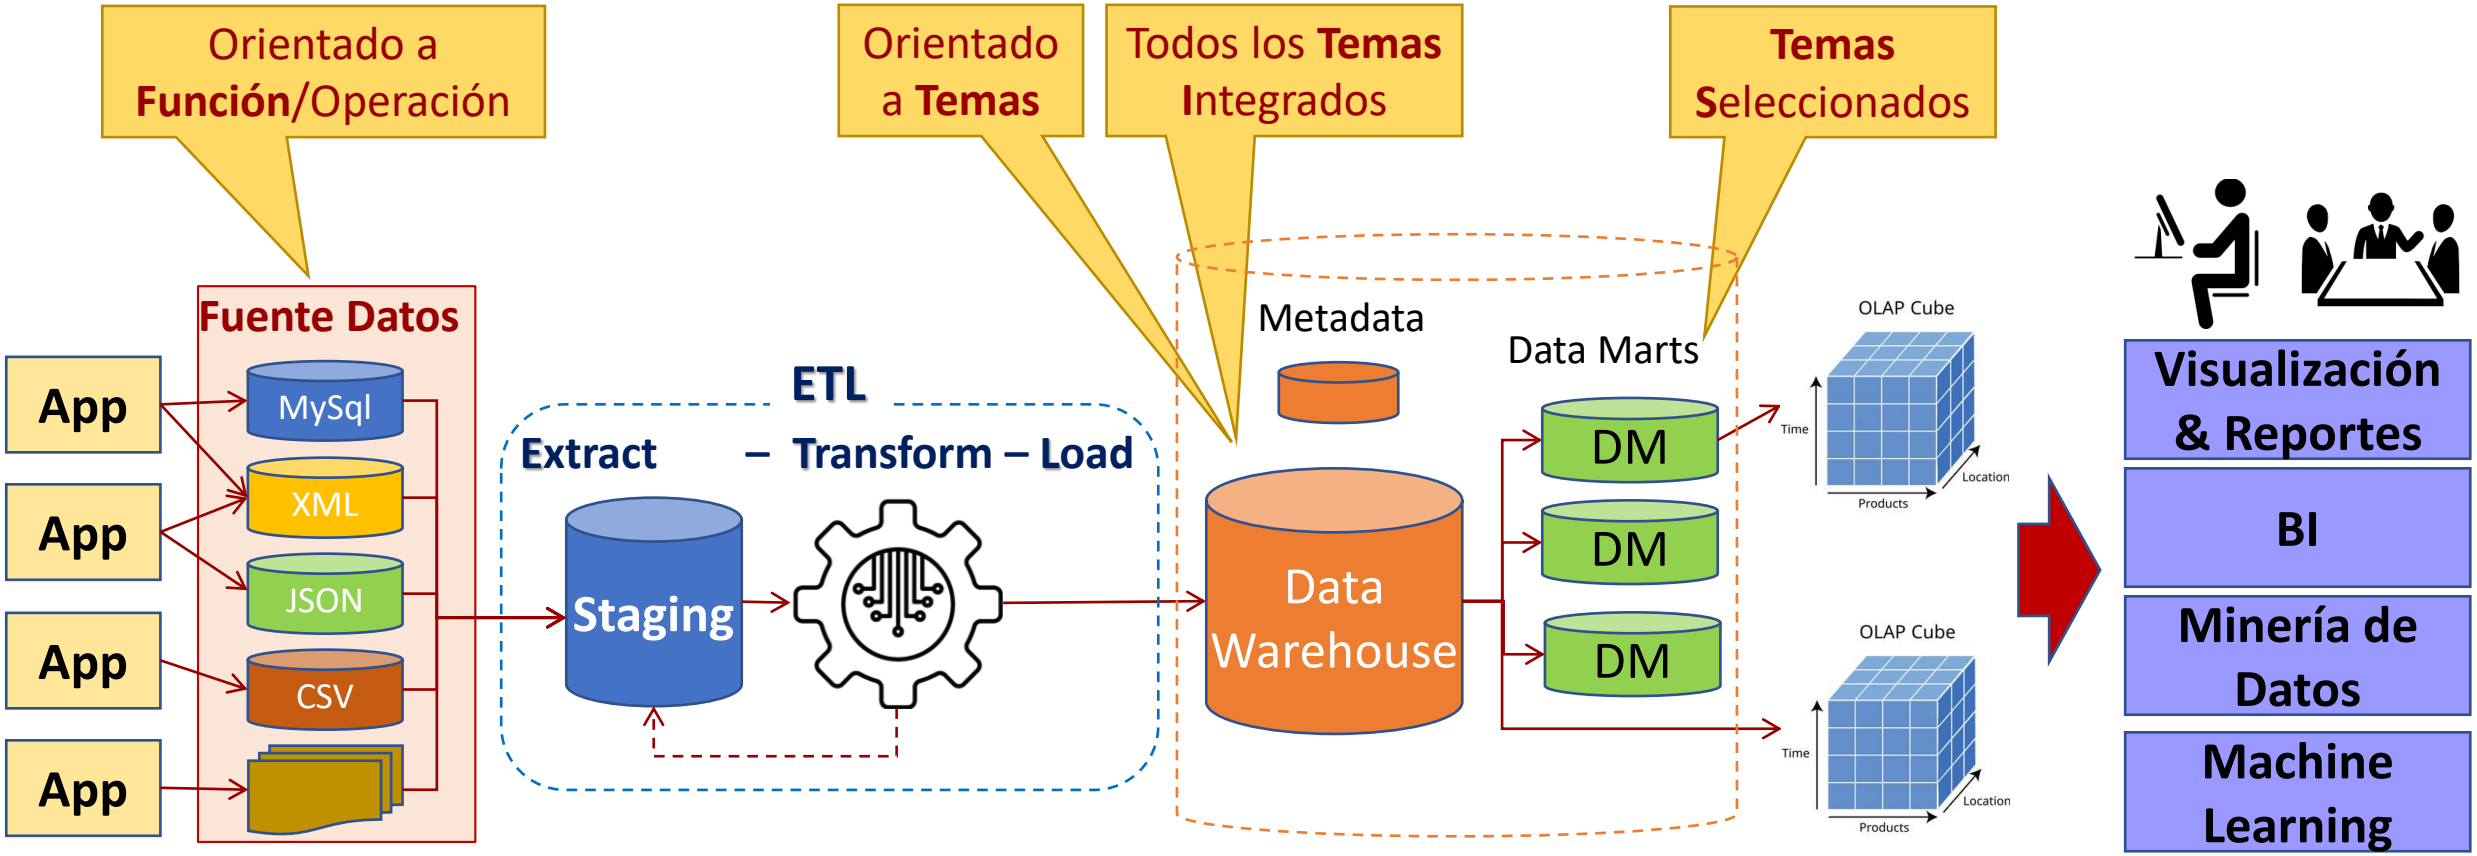

Data Warehouse

- **Características:**
  - **Orientado a tema (*subject*)**:
    - Un *DW* siempre se orienta a un **tema** específico de la organización.
    - A diferencia de las **aplicaciones clásicas**, orientadas a **procesos/funciones**.
    - **Ejemplo**: "**Ventas**" puede ser un **tema** específico
  - **Integrado**
    - Un *DW* integra datos de diferentes **fuentes**.
    - La integración se beneficia de convenciones de **nomenclatura consistentes**, una **estructura de código consistente**, etc.
    - **Por ejemplo**, la **fuente A** y la **fuente B** pueden tener **diferentes formas** de identificar un **producto**, pero en un **DW** solo habrá **una forma de identificar un producto**.

Data Warehouse

- **Características:**
  - **Variante en el tiempo**
    - El *DW* almacena datos **históricos**.
    - **Por ejemplo**, se pueden **recuperar datos de 3, 6, 12 meses** o incluso más **antiguos** de un **DW**. Esto contrasta con un sistema de transacciones, donde a menudo solo se conservan los datos más recientes.
    - Por **ejemplo**, un **sistema de transacciones** puede almacenar la **dirección más reciente de un cliente**, mientras que un **DW** puede almacenar **todas las direcciones** asociadas a un **cliente**.
  - **No volátil**
    - Los **datos nunca se eliminan** ni se modifican en un **DW – datos históricos**.

Data Warehouse

- **Casos de Uso:**
  - Muchas organizaciones crean **DWs** para respaldar la **toma de decisiones** empresariales por las siguientes **razones**:

1. **Mejorar la atención al cliente**, lo que incluye el análisis de sus patrones de compra (como preferencias, tiempo de compra, ciclos presupuestarios y apetito de gasto).
2. **Reposicionar productos** y gestionar las carteras de productos comparando el rendimiento de las ventas por trimestre, año y región geográfica, con el fin de optimizar las estrategias de producción.
3. **Analizar las operaciones** y buscar fuentes de **beneficios**.
4. **Gestionar las relaciones con los clientes**, realizar **correcciones ambientales** y gestionar el coste de los activos corporativos.
5. **Previsión de ventas de productos.**
6. **Apoyar la actividad de inteligencia de negocios (BI).**

Data Warehouse

- **Casos de Uso: EJEMPLOS**
  - **Banca y Finanzas**
    - Para el **análisis de riesgos**, la detección de fraudes y la segmentación de clientes.
    - Al combinar los datos de transacciones de diversas sucursales y canales digitales, pueden predecir el comportamiento del cliente y optimizar los servicios.
  - **Comercio Electrónico**
    - Para analizar el **comportamiento del comprador**, recomendar productos y optimizar las campañas de marketing.
    - Los datos de transacciones, búsquedas e historiales de compras se analizan para ofrecer una experiencia de usuario más personalizada.
  - **Salud (**Hospitales e instituciones sanitarias)
    - Para gestionar los **historiales médicos de los pacientes**, supervisar la eficacia de los tratamientos y respaldar la investigación clínica.
    - Los datos históricos permiten el análisis de tendencias sanitarias a largo plazo.
  - **Gobierno**
    - Para la **planificación de políticas** basadas en datos.
    - Por ejemplo, los datos demográficos, económicos y sociales de diversas regiones se pueden combinar para supervisar el desarrollo regional y formular estrategias de desarrollo.
  - **Empresas de Telecomunicaciones**
    - Para el **análisis del tráfico de red**, la segmentación de clientes y la detección de la pérdida de clientes.
    - Esta información les ayuda a mejorar los servicios y a diseñar paquetes que se adapten mejor a las necesidades de los usuarios.

Data Warehouse

Aspecto	BD Operacional	Data Warehouse
Usuarios	Funcionarios	Alta administración
Utilização	Tareas Cotidianas Datos Recientes	Decisiones estratégicas Datos Históricos
Patrón de Uso	Previsíveis	Difícil de prever
Princípio de Func.	Con base en transacciones	Con base en análisis de datos
Valores de datos	Valores actuales y volátiles	Valores históricos e inmutables
Detalle	Alto	Resumido
Organización de datos	Orientado a función/operación	Orientado a tema (Tópico)

Data Warehouse

- **Modelos de Almacenamiento de Datos**
  - **Warehouse Empresarial (DW)**
    - Recopila datos sobre **temas** que abarcan toda la **organización,** los **integra** y pone **a disposición** para **análisis**.
    - **Muchas fuentes** de **datos** de entrada.
    - Almacena **datos estructurados**.
    - Complejo de **modificar**.
    - Normalmente, **tamaño >100 GB**.
    - Requiere un **modelado de negocio exhaustivo** y su diseño y construcción pueden tardar meses.

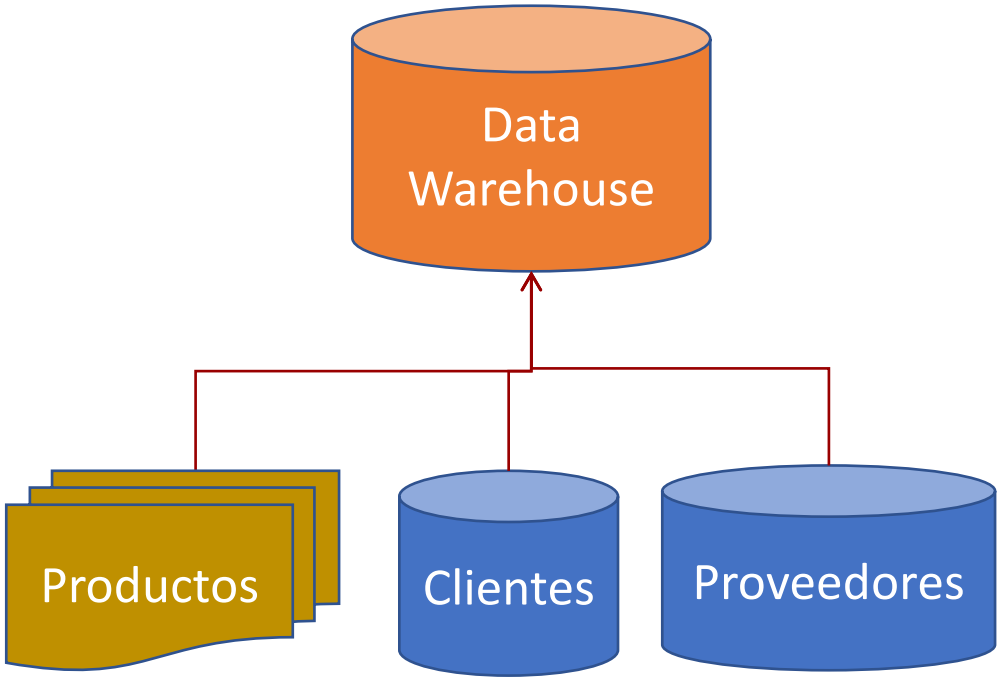

Data Warehouse

- **Modelos de Almacenamiento de Datos**
  - **Data Mart (DM)**
    - Una base de **datos relacional** para análisis.
    - Los **datos** se **centran** en **un área temática**, o grupo de usuarios.
    - **Pocas fuentes** de datos de entrada.
    - Normalmente, **tamaño < 100 GB**.
  - **Warehouse Virtual (SQL View)**
    - Conjunto de **vistas** (views) sobre **bases de datos operativas**.
    - Para procesamiento eficiente de **consultas**.
    - Fácil de construir, pero requiere capacidad adicional en los servidores de bases de datos operativas.

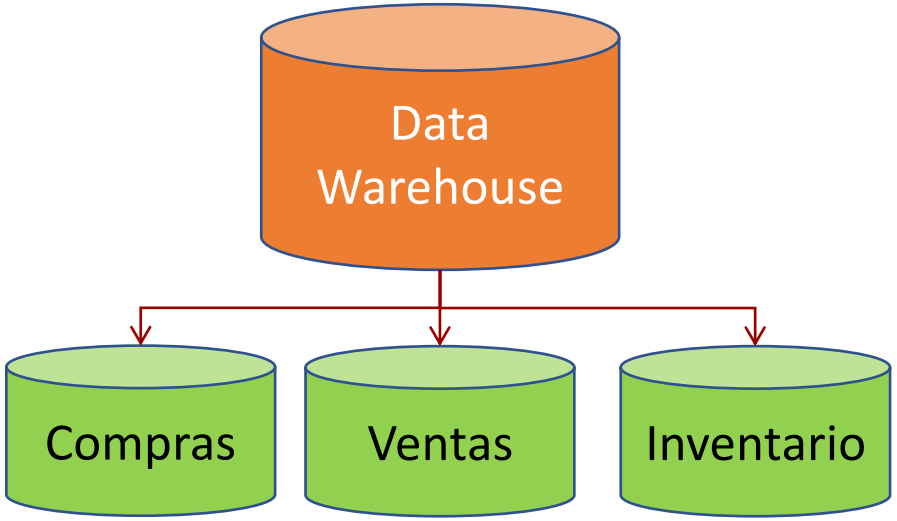

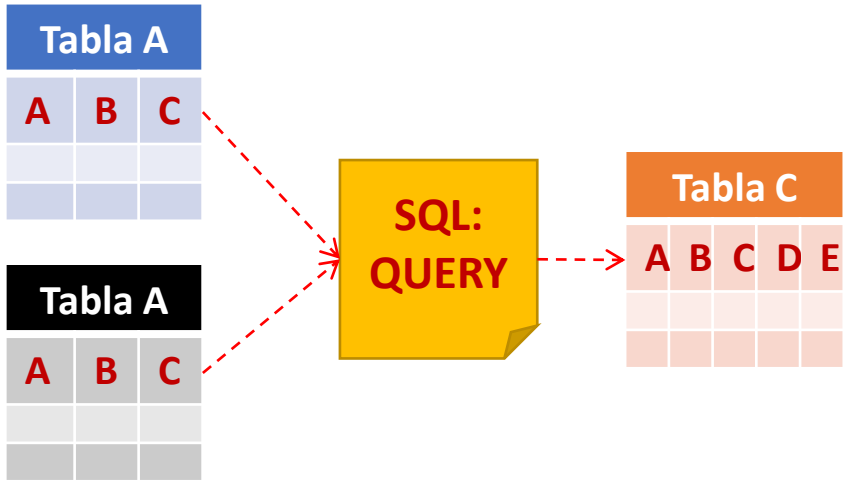

Data Warehouse

- **Repositorio Meta Data:**
  - Almacena **información** sobre el **DW** y su **contenido**.
    - **Datos** sobre los **datos** que definen el **DW**.
      - Descripción de la **estructura del DW**: **Esquema**, vista, dimensiones, data marts , …
      - **Dato operacional**: Histórico de datos y transformaciones aplicadas, estado del dato (activo, archivado, eliminado),…
      - **Algoritmos** usados para resumenes, consultas, temas, agregaciones, …
      - **Mapeamiento** del entorno operacional (OLTP) al DW
      - **Rendimiento**: índices y profiles que mejoran el acesso y consulta
      - **Metadata del negocio**: términos, definiciones, autoría de datos, …
    - Se utiliza para **construir**, **mantener** y **gestionar** el **DW**.

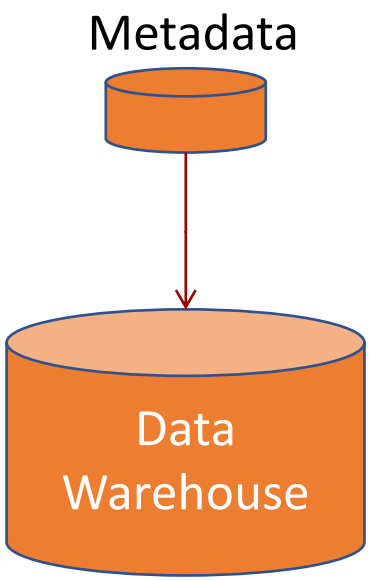

Data Warehouse

- **Arquitectura de una DW - Capas**

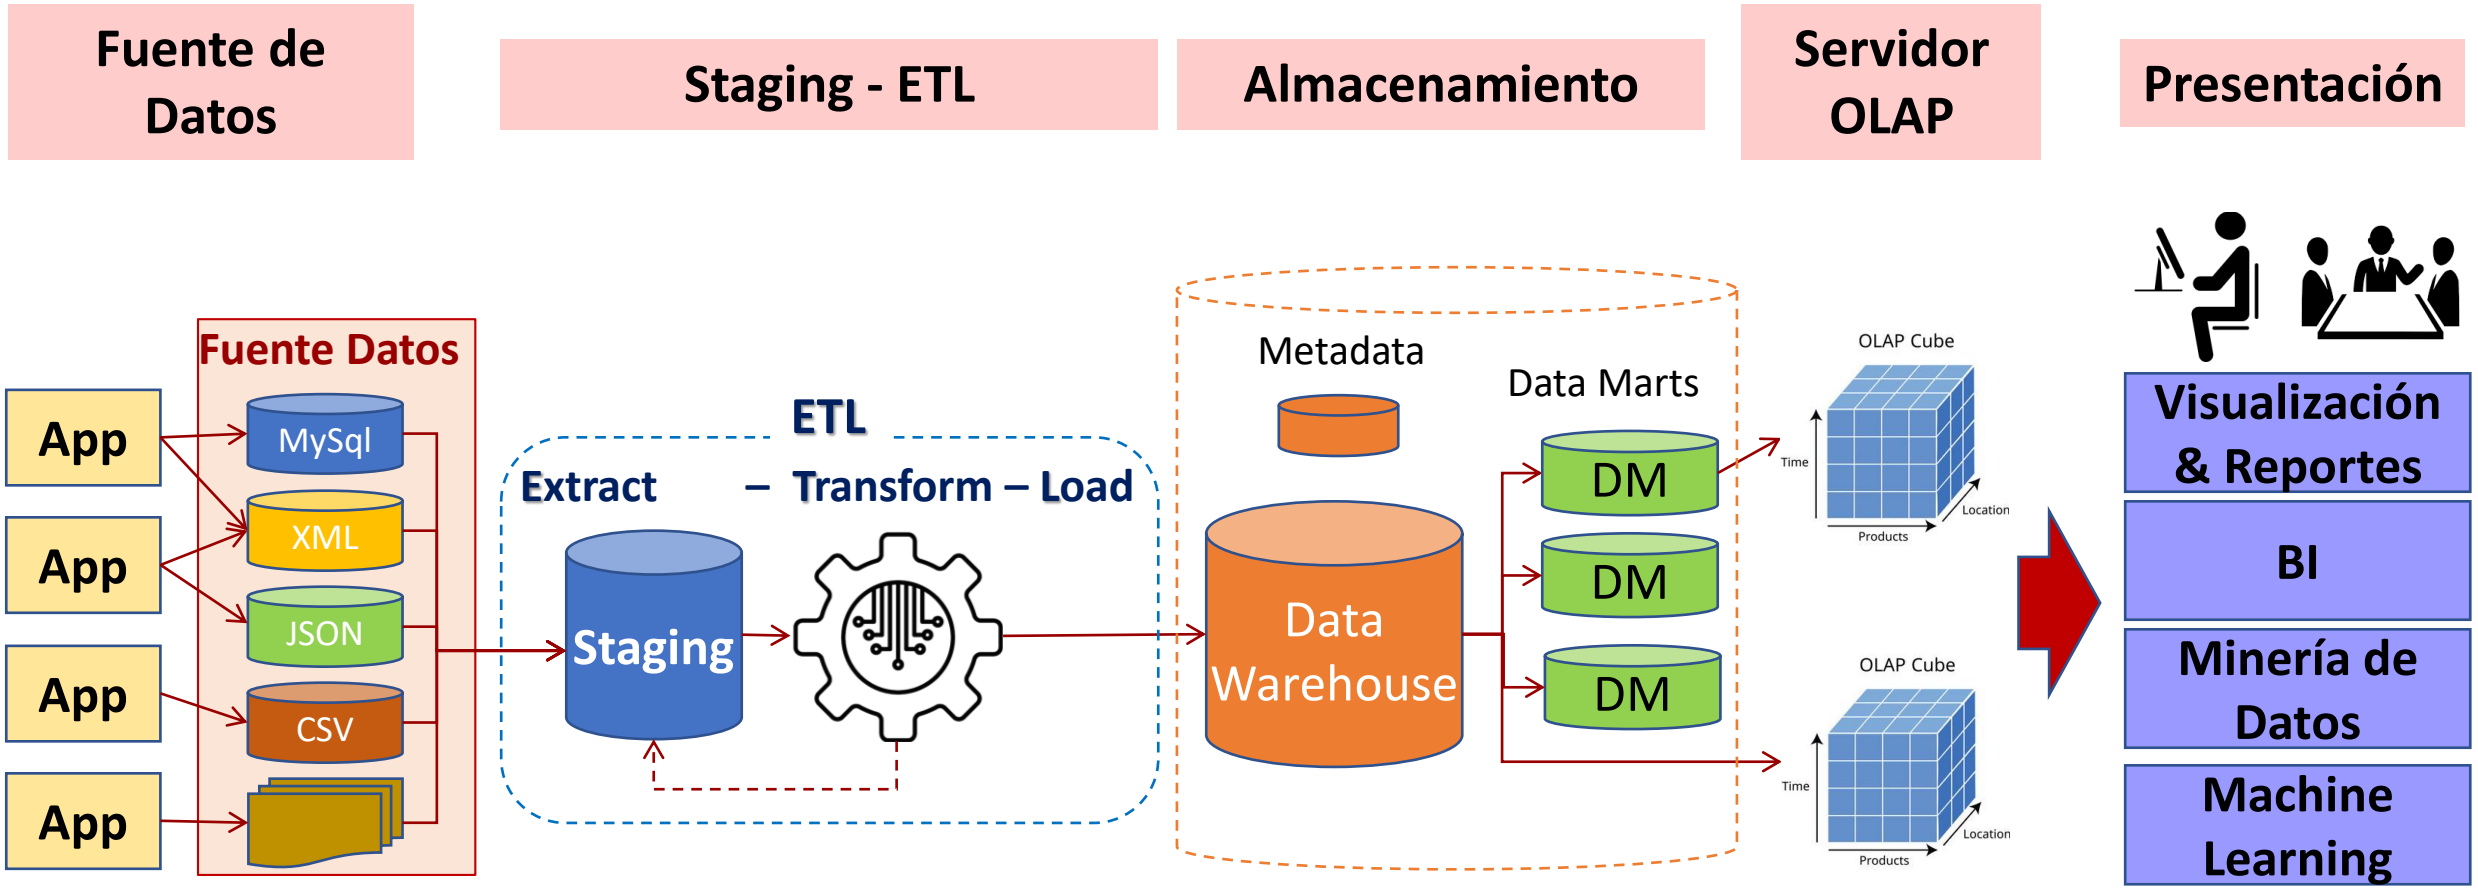

Data Warehouse

- **Arquitectura de una DW – Capas**
  - **Fuente de Datos**:
    - Todas las **fuentes de datos internas y externas** para el **DW**
    - Ejemplos de fuentes de datos:
      - Bases de datos transaccionales
      - Archivos de registro
      - Hojas de cálculo
      - Redes Sociales
      - APIs, …

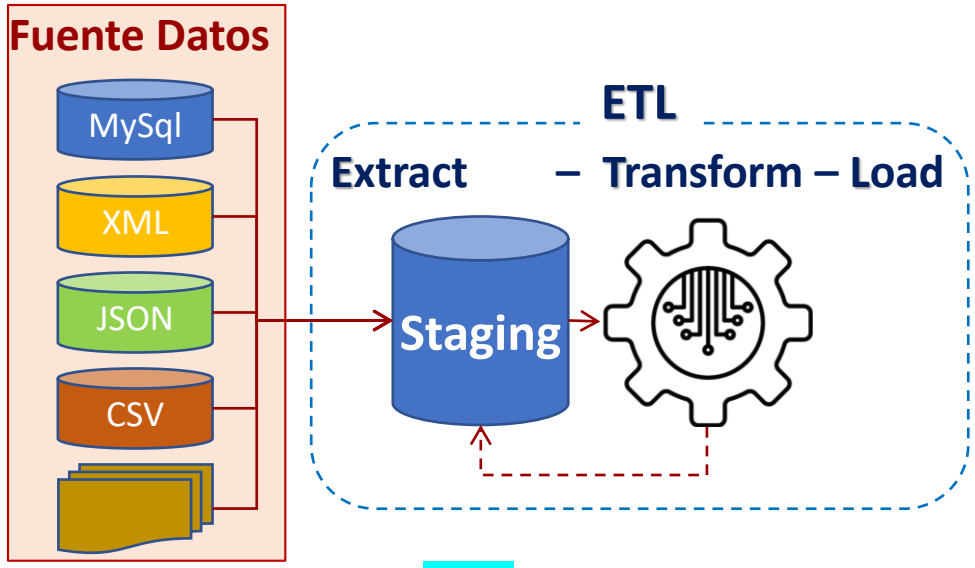

  - **Staging**
    - **Extrae, Transforma** y **Carga (load) datos** mediante el proceso **ETL**.
      - Aplica **reglas de negocio**
      - → **Datos válidos (calidad y consistencia)**
    - Contiene el **proceso ETL** y **tablas** de almacenamiento.

Data Warehouse

- **Arquitectura de una DW – Capas**
  - **Almacenamiento de Datos**:
    - Los **datos** se almacenan en **DWs** y **Data Marts**.
      - **Modelo Relacional (o no)**
      - DW → Data mart
      - Data mart → DW
  - **Servidor OLAP**
    - Ofrece una **visión abstracta** de la **base de datos**.
    - **Organiza** los **datos** en estructuras lógicas **multidimensionales** más **adecuados para el análisis**.
      - Modelo **multidimensional**
      - **Cubo OLAP**
      - **Usuario** elige por cual **dimensión** desea ver los datos
    - Esto se realiza mediante un **servidor OLAP**, implementado mediante el modelo **ROLAP** o **MOLAP**.

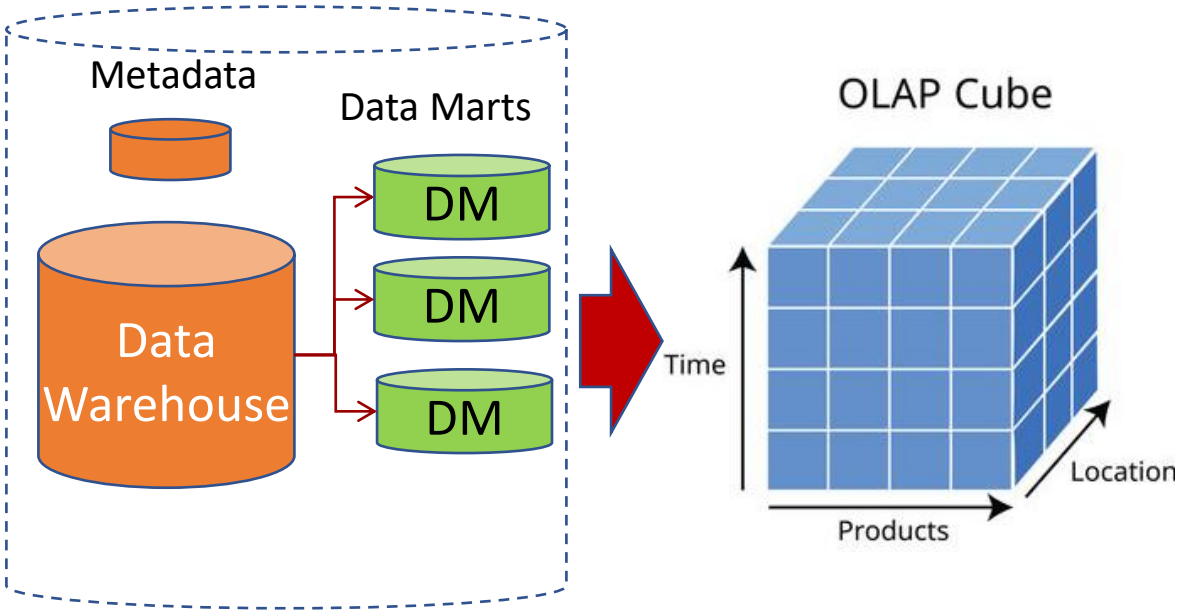

Data Warehouse

- **Arquitectura de una DW – Capas**
  - **Presentación**
    - Los **datos** almacenados se **organizan** y **estructuran** de manera que sean accesibles para **herramientas** de **BI** y otras aplicaciones de análisis.
    - Los **usuarios especialistas** interactúan con los **datos** almacenados mediante:
      - **consultas directas: SQL, OLAP**
      - herramientas de **Inteligencia de Negocios (BI).**
      - herramientas de **Minería de Datos (DM).**
      - herramientas de **Machine Learning (ML)**.
    - Los **usuarios finales** interactúan con los **datos** mediante un **Producto con Interfaz Gráfica de Usuario (GUI).**

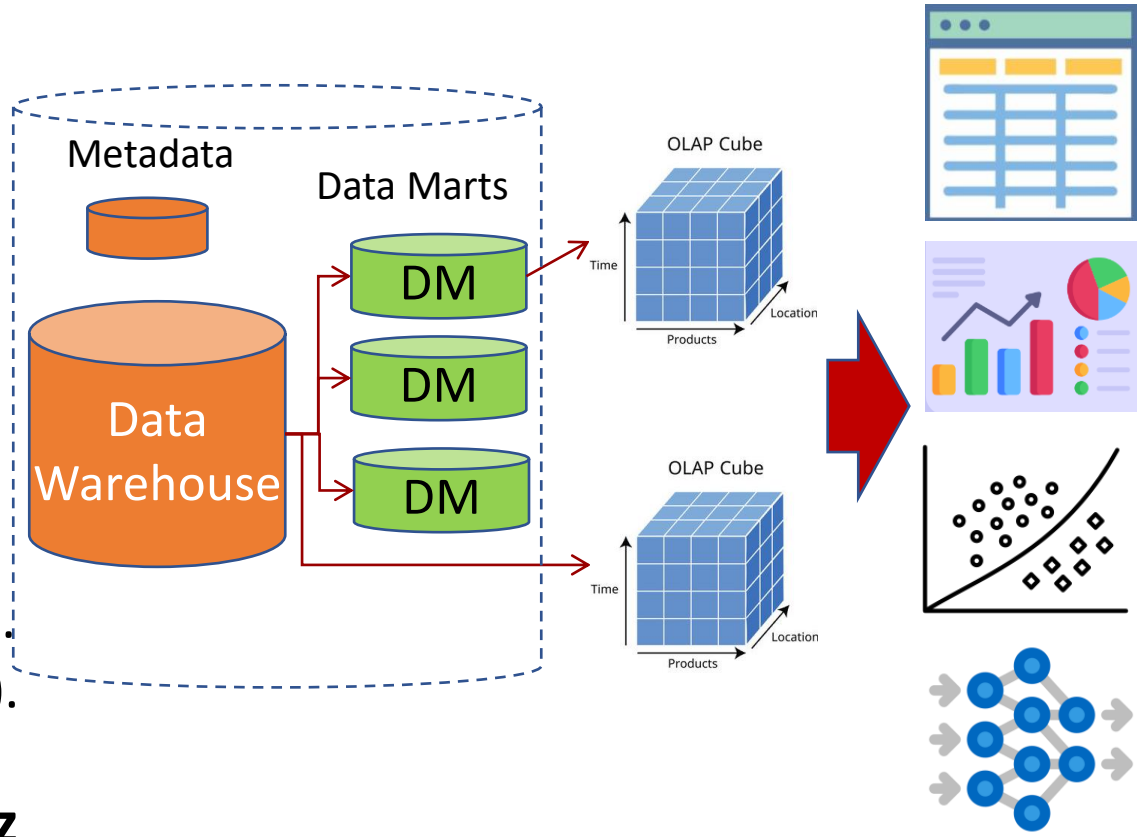

Data Warehouse

- **Proceso de diseño de un DW:**

Top-down:
1. Diseño de DW
2. Diseño de DMs

- comienza con el **diseño** y la **planificación** general.
- Es **útil** en casos donde la **tecnología es madura** y bien conocida, y donde los **problemas de negocio** que deben resolverse son **claros** y bien **comprendidos**.

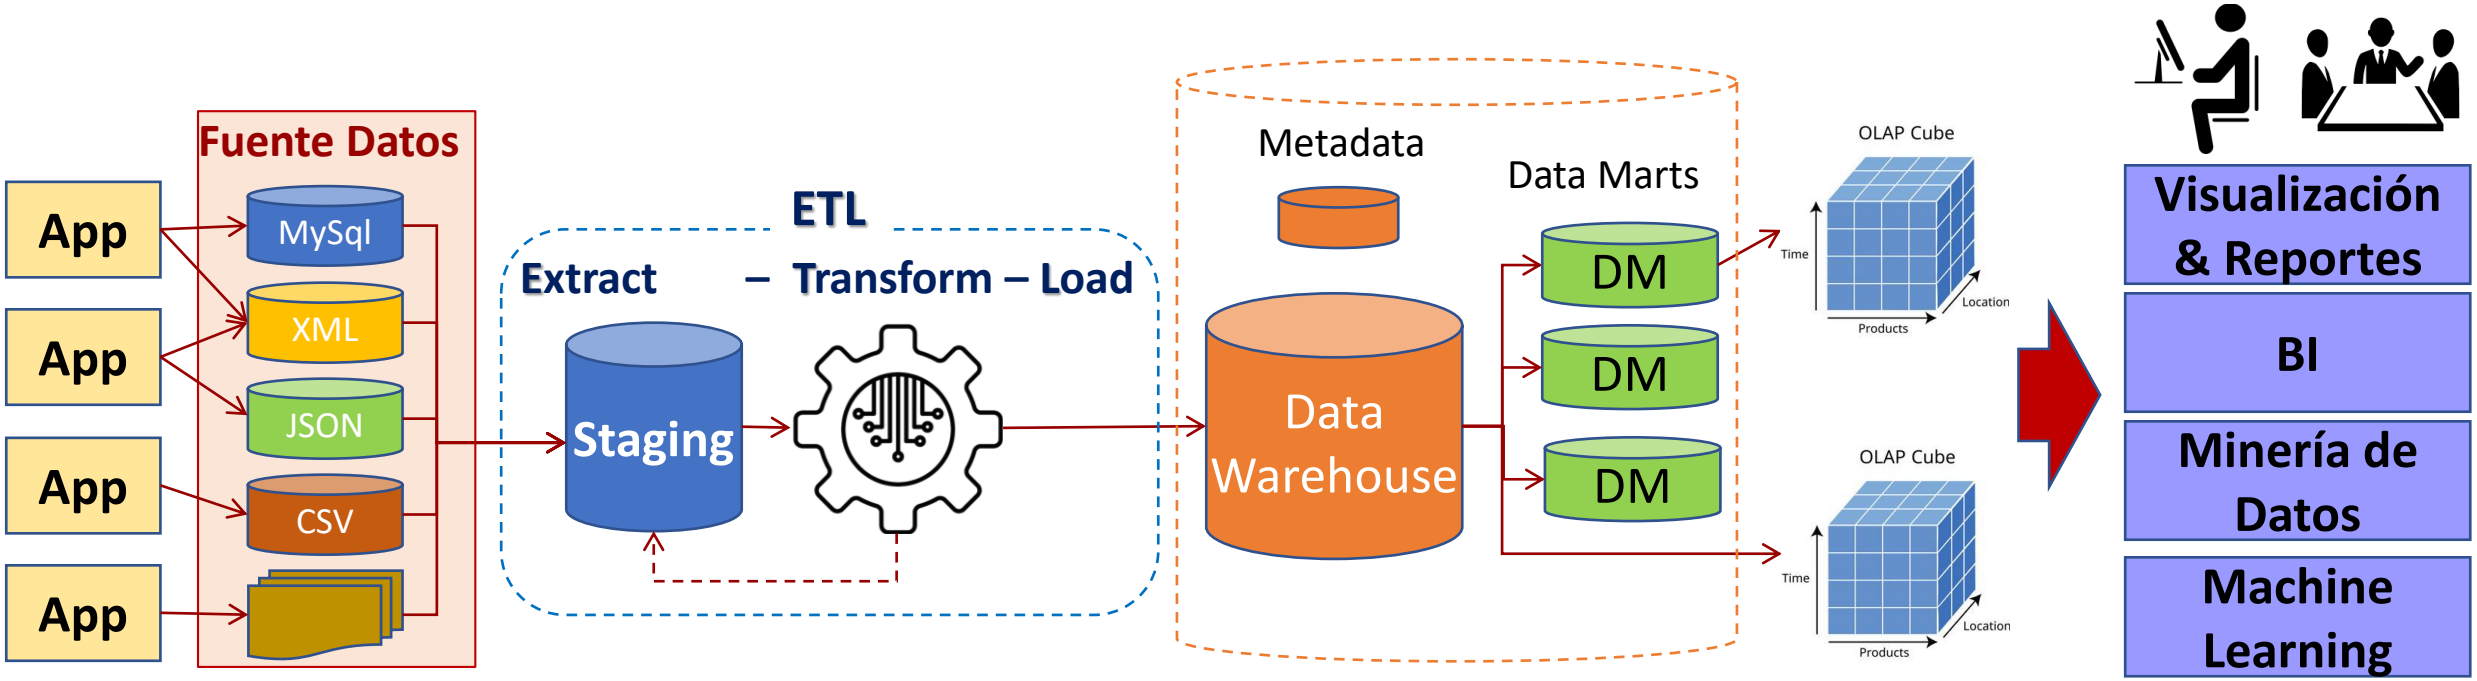

Data Warehouse

- **Proceso de diseño de un DW:**

  - comienza con **experimentos** y **prototipos**.
  - Es **útil** etapas iniciales del **modelado del negocio** y desarrollo **tecnológico**
  - Permite **evaluar beneficios** sin **asumir compromisos**.

Bottom-up

1. Diseño de DM
2. Posible integración de DMs en DW
3. Posible ausencia de DW

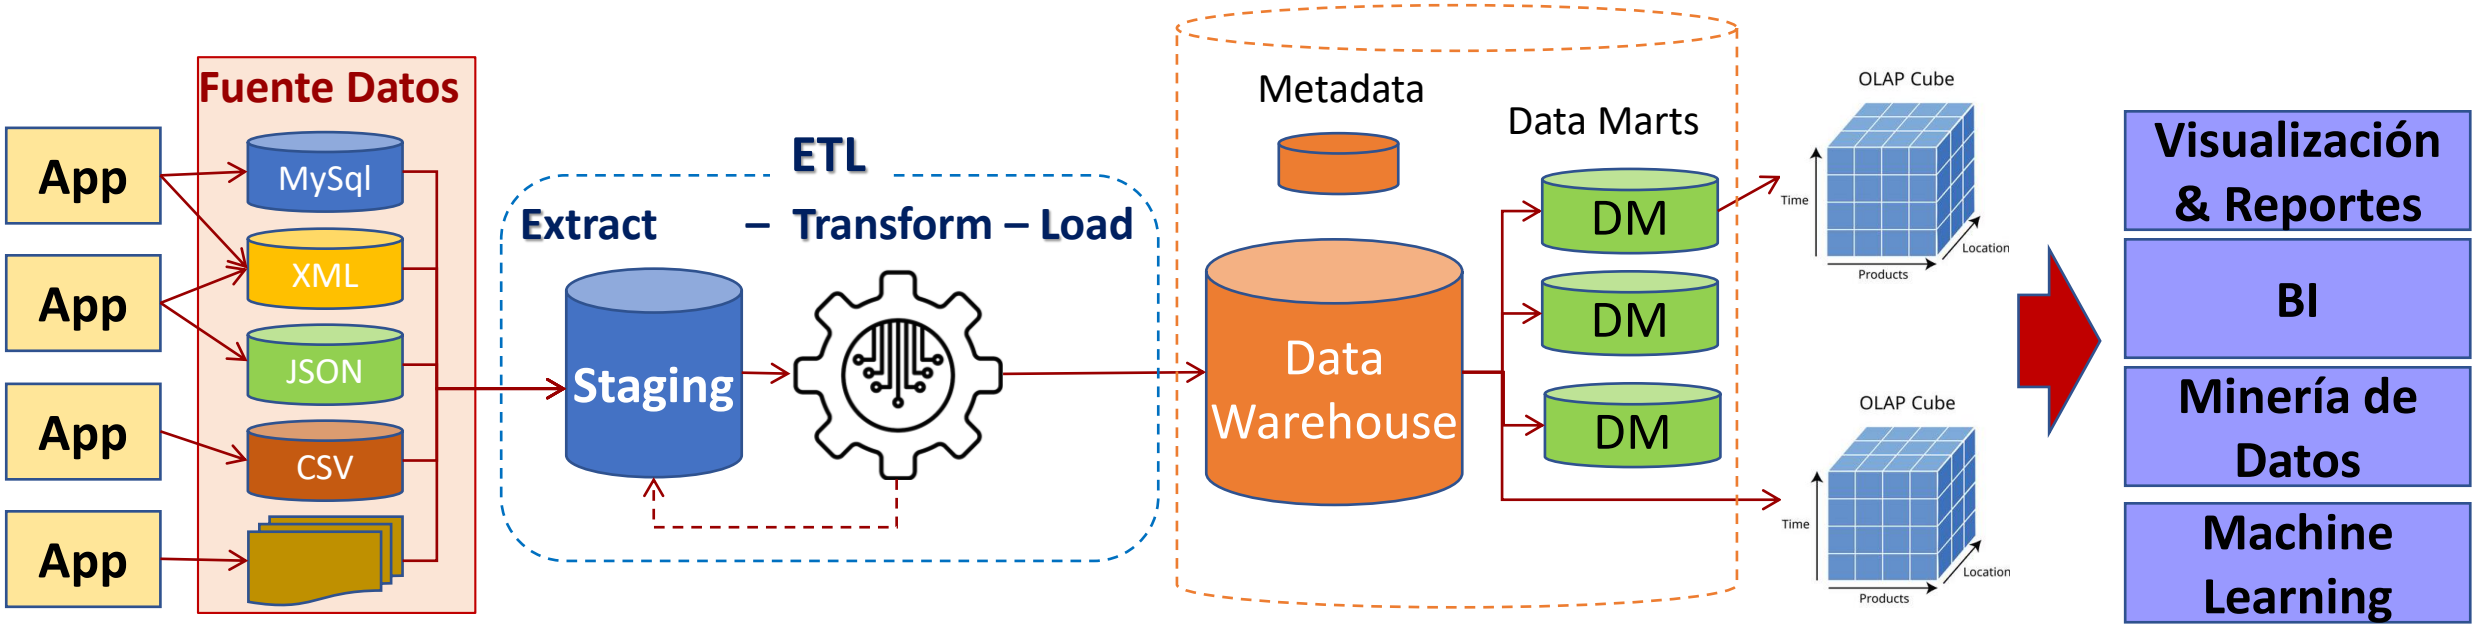

Data Warehouse

- **Proceso de diseño de un DW:**

Combinado (In-between):
1. Diseño de DW para DM1
2. Diseño de DM2 e integración con DW
3. Diseño de DM3 e integración con DW
4. ...

- Aprovecha la **naturaleza planificada** y estratégica del **enfoque top-down**, a la vez que conserva la **rápida implementación** y la aplicación oportuna del enfoque **bottom-up**.

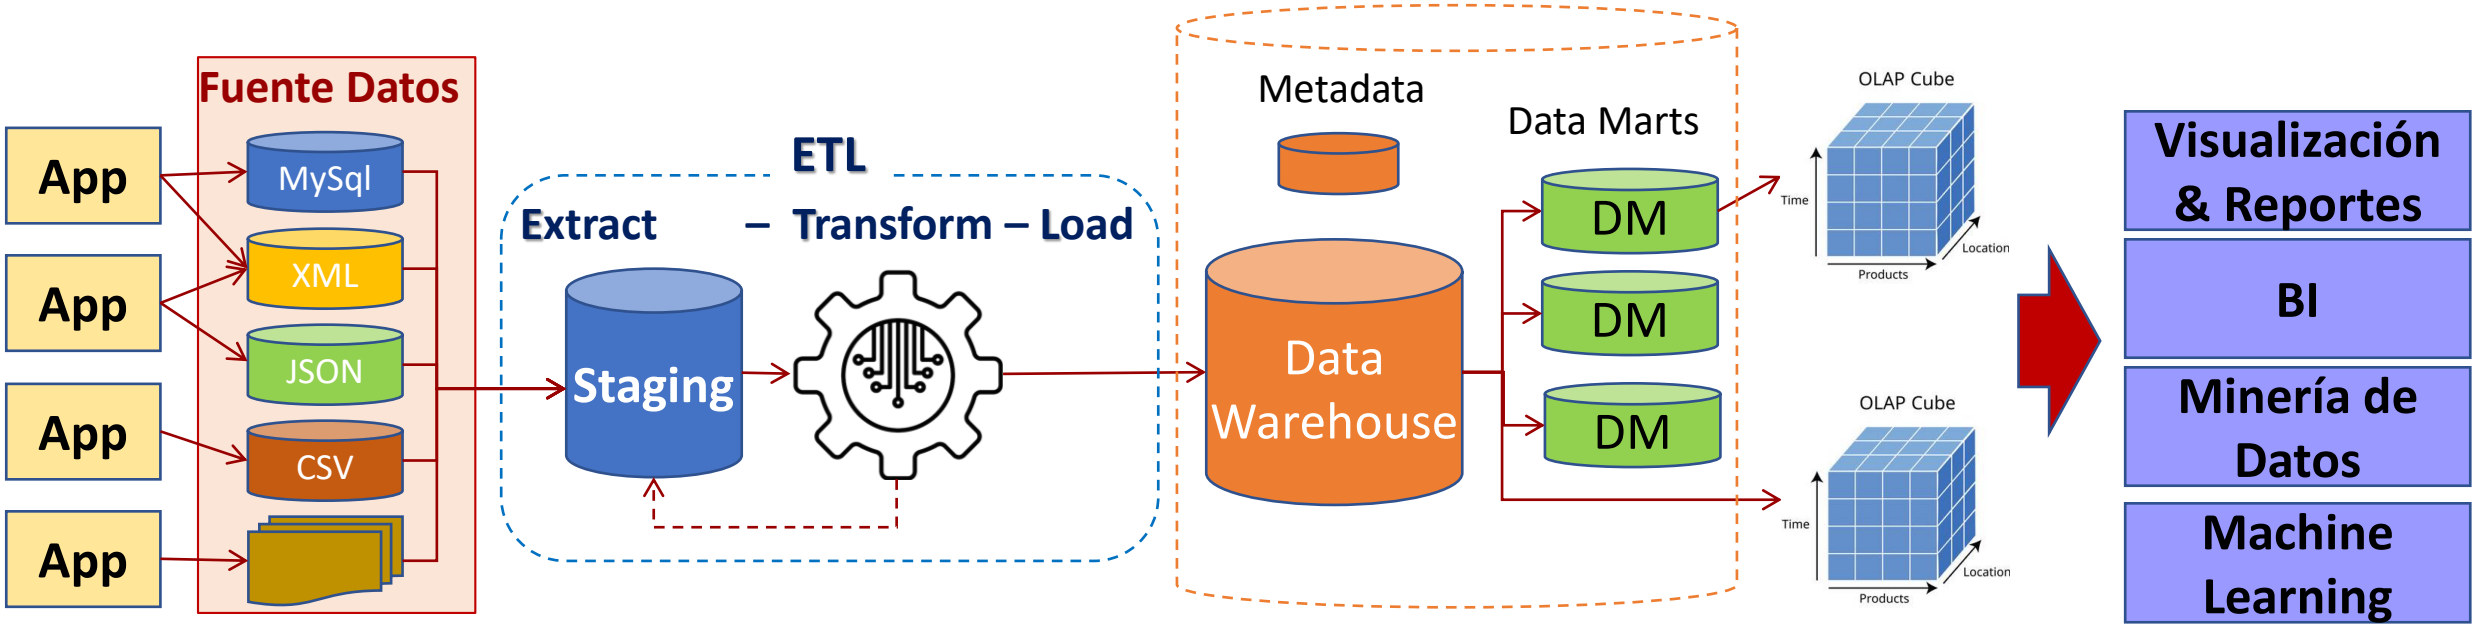

Ciclo de Vida de un DW

Los analistas de negocios se reúnen con las partes interesadas para:

Planificación

1. Identificación de Objetivos
2. Identificación de Requisitos de Negocio
3. Definición de KPIs y Métricas
4. Identificación de Fuentes de Datos

Diseño

1. Modelado de Datos
2. Arquitectura del Sistema
3. Diseño del proceso ETL

Implementación

1. Implementación ETL
2. Implementación de Aplicaciones: Consultas SQL/OLAP, BI, DM, ML, …

Evolución

1. Pruebas
2. Despliegue
3. Monitoramiento
4. Mantenimiento

Ciclo de Vida de un DW

- **PLANIFICACIÓN**:
  1. **Identificación de Objetivos**
     - **Objetivo**: Determinar qué espera **lograr la organización** con el **DW**
     - **Papeles**: Analista o Científico de Datos, y partes interesadas de la organización
     - **Ejemplos**:
       - Integrar Datos
       - Mejorar la toma de decisiones
       - Aumentar la eficiencia operativa
       - Comprender al cliente
       - Proveer datos históricos
       - Análisis predictivo
       - …

Comercio electrónico: Analizar el comportamiento del comprador, personalizar las recomendaciones, optimizar el marketing y hacer seguimiento de la logística.
Banca/Finanzas: Detectar fraudes, evaluar riesgo, segmentar a los clientes y analizar la rentabilidad.
Salud: Supervisar la eficacia de los tratamientos, gestionar los historiales clínicos de los pacientes.
Telecomunicaciones: Analizar el tráfico de la red, segmentar a los clientes y prever la pérdida de clientes.
Gobierno: Formular políticas basadas en datos y supervisar el desarrollo regional.

Ciclo de Vida de un DW

- **PLANIFICACIÓN**:
  2. **Identificación de Requisitos de Negocio**
     - **Objetivo**: Identificar las **necesidades** específicas de los diferentes **departamentos y usuarios** dentro de la **organización**
     - **Papeles**: Analista o Científico de Datos , y p
     - Esto puede incluir **requisitos** de
       - informes,
       - análisis ad hoc,
       - integración de datos, etc.
         - Auditabilidad
         - Inmutabilidad
         - Latencia
         - …
         - Reportes deben cargarse en menos de 3 segundos
         - Reportes deben considerar los últimos 7 años

Ventas: tendencias de ventas por región, producto, promoción, …
Finanzas: previsión de ingresos, análisis de márgenes, informes regulatorios.
Marketing: segmentación de clientes, modelos de atribución, ROI de campañas.
Operaciones: seguimiento de la cadena de suministro, mantenimiento predictivo.
Cumplimiento normativo: registros de auditoría para agencias reguladoras.

Ciclo de Vida de un DW

- **PLANIFICACIÓN**:
  3. **Identificación de KPIs y Métricas**
     - **Objetivo**: Establecer indicadores clave de rendimiento (**KPIs**) y métricas para **medir** el **éxito del DW**.
     - **Papeles**: Analista o Científico de Datos , y partes interesadas de la organización
     - Los **KPIs** deben estar alineados con los **objetivos** de negocio
     - Los **KPIs** están orientados hacia la: **Calidad de los Datos**, **Rendimiento del DW**, y **Areas de la Organización** como **finanzas**, **marketing**, **ventas** y **recursos humanos**.

Finanzas	Marketing	Recusros Humanos	Ventas
• Capital de trabajo. • Flujo de caja operativo. • Retorno sobre el capital. • Inventario. • Cuentas por cobrar. • Margen bruto de beneficio.	• Costo de adquisición del cliente. • Tasa de conversión del canal determinado. • % de clientes potenciales generados por un canal determinado. • Perdida del cliente. • Clientes inactivos. • Gasto medio del cliente.	• Tasa de rotación voluntaria de empleados. • Duración media de servicio de empleados. • Media de tiempo de formación de personal • Calificación de desempeño. • Presupuesto destinado a capacitación de nuevo personal. • Tasa de ausentismo.	• Margen bruto (% del precio de venta) • Inventario • % de venta directa • Venta promedio por transacción • % del stock total no mostrado

Ciclo de Vida de un DW

- **PLANIFICACIÓN**:
  4. **Identificación de Fuentes de Datos**
     - **Objetivo**: Identificar todas las **fuentes de datos** relevantes que se **integrarán** en el **DW**.
     - **Papeles**: Analista o Científico de Datos
     - Incluye:
       - **Sistemas internos**: CRM, ERP, RR.HH., finanzas, registros de IoT, datos de sensores, flujo de clics.
       - **Fuentes externas**: API de socios, datos de mercado, ...
     - Para cada uno, **evalue**:
       - **Volumen** (filas por día, tamaño de almacenamiento).
       - **Velocidad** (lotes, microlotes o streaming).
       - **Variedad** (tablas SQL estructuradas vs. NoSQL vs. archivos).
       - **Problemas de Calidad** (duplicados, valores faltantes, IDs inconsistentes).
       - **Restricciones Regulatorias** (p. ej., los datos de los clientes deben permanecer en ...).

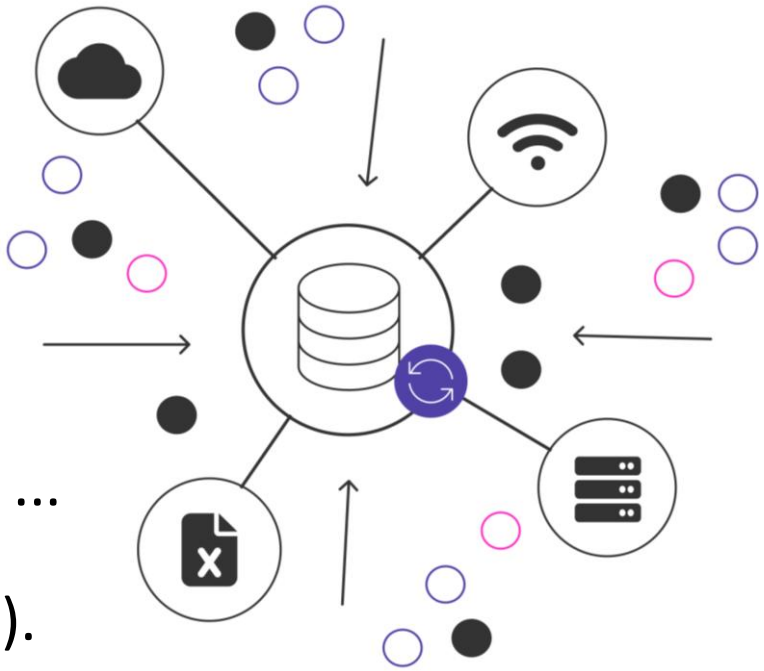

Ciclo de Vida de un DW

- **DISEÑO**:
  - **Modelado de Datos**
    - **Objetivo**: Crear un **modelo de datos** que represente la **estructura** y las **relaciones** entre los diferentes elementos de **datos**
    - **Papeles**: Analista o Científico de Datos, DBA
    - Incluye:
      - **Esquemas Estrella (Star)**: Tabla de **hechos central** (p. ej., Ventas) con **tablas de dimensiones** (p. ej., Producto, Cliente).
      - **Esquema Copo de Nieve (Snowflake)**: Las **dimensiones normalizadas** reducen la redundancia, pero añaden **joins**.
      - **Diagramas de entidad-relación (ERD)**.
      - **Tablas anchas**: Optimizados para **ML**, menos flexibles para **BI**.
      - **Cubo Multidimensional**: Facilita las operaciones OLAP.

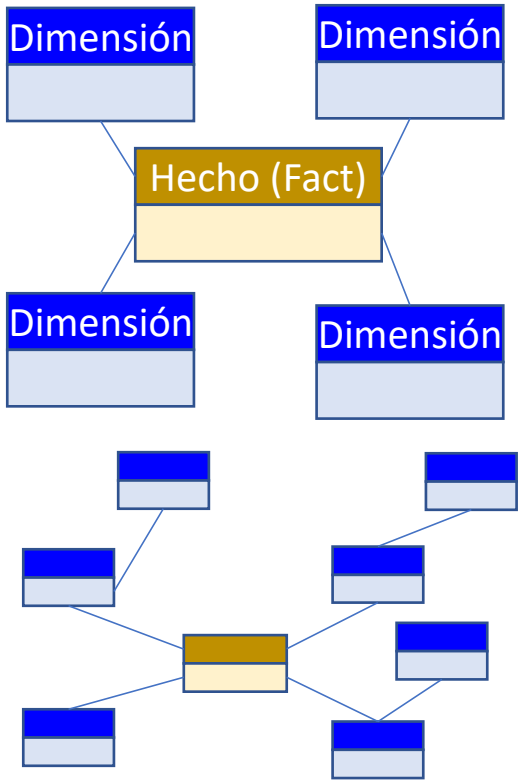

OLAP Cube

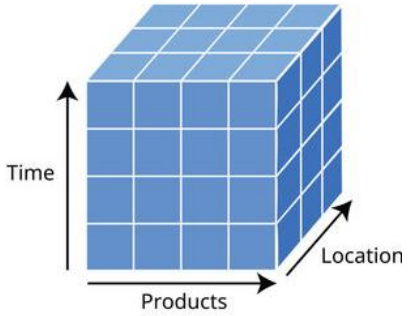

Ciclo de Vida de un DW

- **DISEÑO** :
  - **Arquitectura del Sistema**
    - **Objetivo**: Definir la **arquitectura técnica** del **DW**, incluyendo **hardware**, **software**, **almacenamiento** y **red**
    - **Papeles**: Ingeniero de Datos, DBA

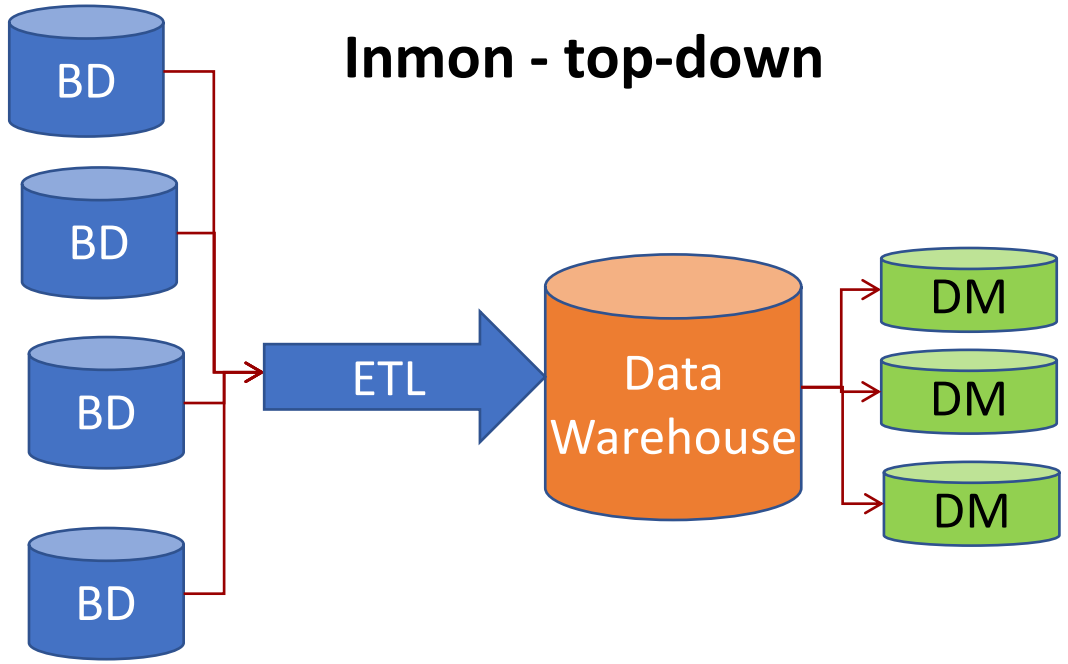

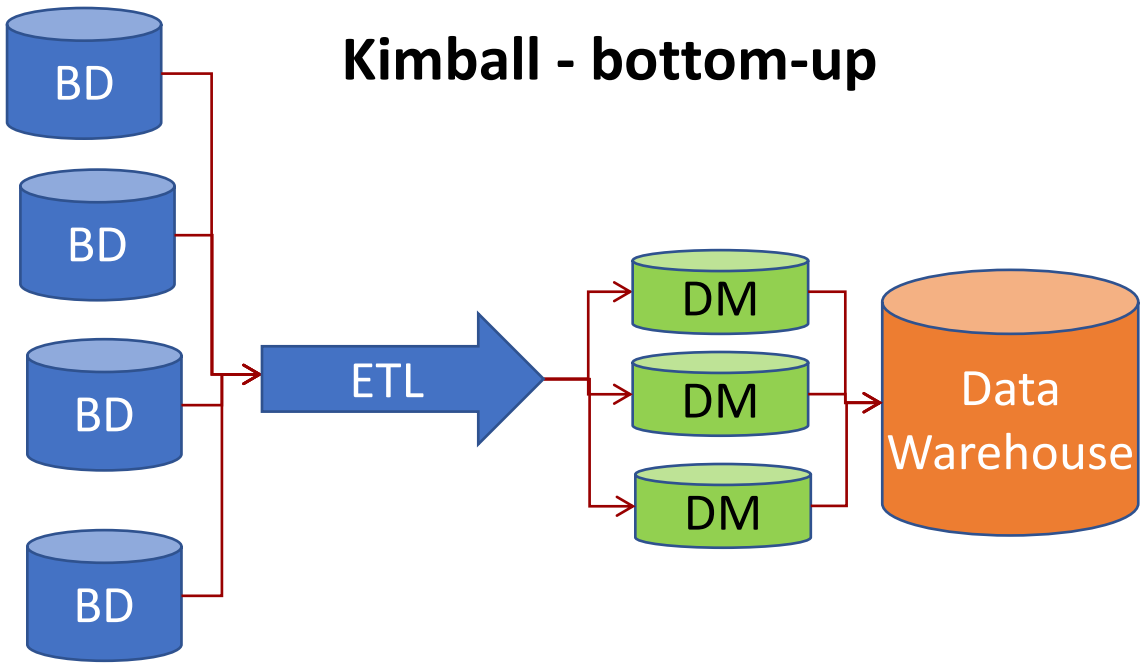

Ciclo de Vida de un DW

- **DISEÑO**:
  - **Diseño del Proceso ETL**
    - **Objetivo**: Diseñar los **procesos de extracción**, **transformación** y **carga** (ETL) que moverán los **datos** desde las **fuentes originales** hasta el **DW.**
    - **Papeles**: Ingeniero de Datos, DBA
    - Incluye:
      - **Extracción de Datos**: Recopilar datos de las diversas fuentes identificadas.
      - **Transformación de Datos**: Limpiar, normalizar y transformar los datos para asegurar su calidad y consistencia.
      - **Carga de Datos**: Insertar los datos transformados en el Data Warehouse.
        - Esto puede incluir una carga inicial masiva y cargas incrementales periódicas.

Ciclo de Vida de un DW

- **IMPLEMENTACIÓN:**
  - **Implementación de ETL**
    - **Objetivo**: Implementar pipelines de datos (proceso ETL)
    - **Papeles**: Analista o Científico de Datos, Ingeniero de Datos
    - Incluye:
      - Seleccionar **herramientas <u>ETL</u>** como **Talend**, **Informatica**, o **Microsoft SSIS** para la integración de datos.
      - Elegir una **plataforma de <u>almacenamiento</u>** adecuada, como **Amazon Redshift**, **Google BigQuery**, **Snowflake**, o una solución **on-premises** como **PostegreSQL**, **Oracle, SQL Server (SSAS) o SQL Server (SISS - Cubes)**.
      - .

PostgreSQL ORACLE snowflake Amazon Redshift Google BigQuery

Ciclo de Vida de un DW

- **IMPLEMENTACIÓN:**
  - **Implementación de Aplicaciones**
    - **Objetivo**: Implementar aplicaciones centradas en datos (SQL/OLAP, BI, DM, ML)
    - **Papeles**: Analista o Científico de Datos
    - Incluye:
      - **Herramientas** de **SQL/OLAP, BI, DM, ML que** se utilizarán, como **Tableau**, **Power BI**, o Look
      - **Diseño de interfaz de usuario**: Diseño de interfaces intuitivas que facilitan el análisis de datos y la generación de informes.
      - **Desarrollo de Dashboards**: Creación de paneles que proporcionan información valiosa mediante la visualización de datos.
      - **Generación de Informes**: Implementación de funciones para generar informes según criterios definidos por el u

tableau

Power BI

Ciclo de Vida de un DW

- **EVOLUCIÓN:**
  - **Pruebas**
    - **Objetivo**: Garantizar que el almacén de datos funcione como se espera y cumpla con los requisitos del negocio
    - **Papeles**: Analista o Científico de Datos, Ingeniero de Datos
    - Incluye:
      - **Pruebas de Integridad de Datos**: Verificar que los **datos** se han transferido **correctamente** y que no hay **pérdida de información**.
      - **Pruebas de Rendimiento**: Asegurar que el **DW** puede manejar **las cargas de trabajo** esperadas y que las **consultas** se ejecutan dentro de los **tiempos aceptables**.
      - **Pruebas de Pipeline: V**erificar que el **proceso ETL/ELT** se complete dentro de los **plazos requeridos** y entregue los recuentos de **filas esperados**.
      - **Pruebas de Usabilidad**: Asegurar que los **usuarios** pueden acceder a los datos y generar **los informes necesarios sin problemas**.

Ciclo de Vida de un DW

- **EVOLUCIÓN:**
  - **Despliegue**
    - **Objetivo**: Implantar el DW en un entorno de producción (on-premise, cloud o híbrido)
    - **Papeles**: Ingeniero de Datos
    - Tras la **configuración inicial** del **DW**:
      - Comience con una **implementación limitada** para un **subconjunto de usuarios**.
      - **Valide** los **informes críticos** con los **sistemas de origen** antes de abrir el acceso a equipos más amplios.
      - **Comunique** los **cambios a los usuarios** empresariales para que la adopción sea planificada, no forzada.

Ciclo de Vida de un DW

- **EVOLUCIÓN:**
  - **Monitoramiento**
    - **Objetivo**: Hacer Seguimiento del estado del DW
    - **Papeles**: Ingeniero de Datos
    - **DW en producción**
      - **Monitorear el estado del pipeline**: duración de los trabajos, tasas de error y latencia de datos.
      - **Supervisar el rendimiento y la concurrencia de las consultas** para detectar cuellos de botella.
      - **Recopilar métricas** de actualización de datos.

Ciclo de Vida de un DW

- **EVOLUCIÓN:**
  - **Mantenimiento**
    - **Objetivo**: Mantener los datos operativos sobre su funcionamiento.
    - **Papeles**: Analista o Científico de Datos, Ingeniero de Datos
    - Incluye:
      - **Programar revisiones periódicas** con las partes interesadas del negocio para confirmar que el **DW sigue cumpliendo con los requisitos y objetivos**.
      - **Añadir nuevas fuentes** de forma incremental y vuelva a **evaluar las cargas de trabajo** después de cada **cambio**.
      - **Revisar los modelos de costes periódicamente**, especialmente si el uso del almacenamiento o de los recursos informáticos crece más rápido de lo previsto.

Modelado Multidimensional

- Un **DW** se basa en un **modelo de datos multidimensional** que puede visualizar los datos en forma de **cubos de datos** en **3D**, **4D** y **nD**.
  - Existe un conjunto de **medidas numéricas (o KPIs o métricas)** que se **analizan**.
    - **Ejemplos**: las **ventas**, el **presupuesto**, los **ingresos**, el **inventario** y el **ROI**.
  - Cada **medida numérica** depende de un conjunto de **dimensiones** que proporcionan el **contexto** para la **medida**.
    - Un **cubo de datos**, como el de **ventas (sales)**, permite modelar y visualizar los datos en múltiples **dimensiones (producto, canal de venta y tiempo)**.
    - Cada **celda del cubo** contiene una sola **medida**,

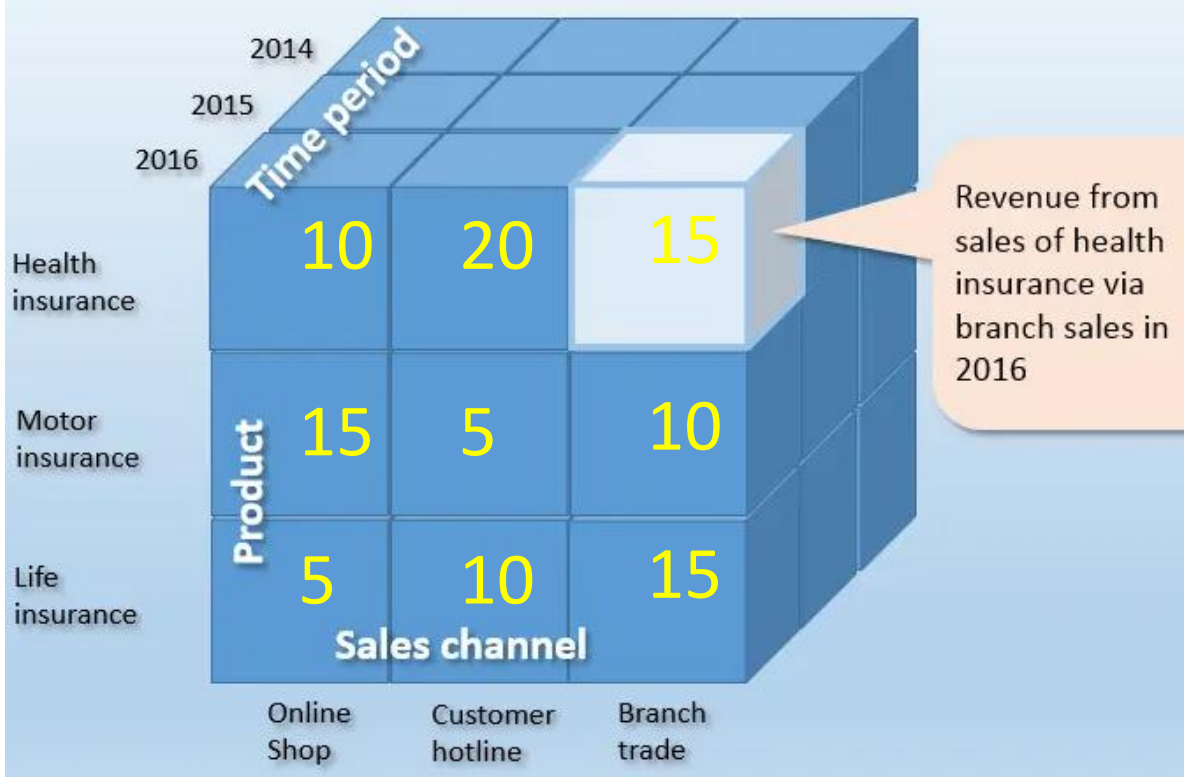

IONOS, 2020

Modelado Multidimensional

- Un **cubo de datos:**
  - Organiza **tablas de dimensiones** alrededor de **una tabla de hechos central** que contiene las **medidas**.
  - Una **tabla de hechos** contiene una **columna** para cada **medida**, así como una columna (*foreign key*) para cada dimensión.
  - La longitud se ve determinada por el número de **celdas**.
  - Cada **celda** contiene una sola **medida**
    - Por ejemplo, el **volumen de ventas** para el **producto** "Seguro de vida" a través del **canal de venta** "Sucursal de venta" en el **año** "2016".

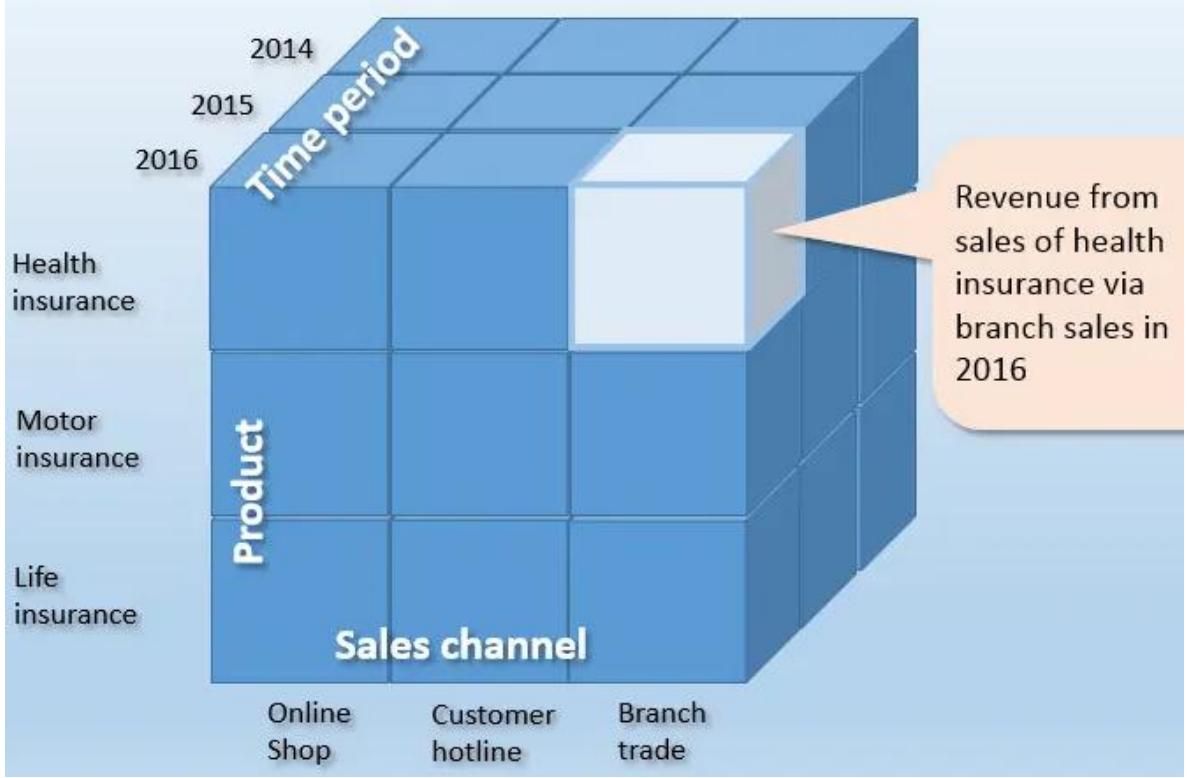

IONOS, 2020

Modelado Multidimensional

- **Un modelo de datos multidimensional suele organizarse en torno a un <u>tema central</u> , como las ventas.**
  - Este **tema** se representa mediante una **<u>tabla de hechos:</u>**
    - Contiene **medidas** (como volumen de ventas).
    - **Regla general**: si una **cifra** tiene sentido comercial al **agregarse**, entonces es una medida.
    - **Ejemplos**:
      - **Volumen de ventas**
      - **Volumen** diario por mes, trimestre y año.
      - **Números de teléfono** no tendría sentido; por lo tanto, no son medidas.
      - **Código postal**: no es una medida, pero puede ser una dimensión.

Modelado Multidimensional

- **Las dimensiones explican el contexto del dato (medida).**
  - Se representan mediante **tablas**.
  - **Regla general:** cuando se solicita un **informe** por "algo", ese "algo" suele ser una dimensión.
  - **Ejemplo**:
    - Productos", "Canal de Venta" y "Tiempo",
    - **Informe de ventas** por **mes** y por **canal**,
      - → **Dimensiones**: **tiempo** y **canal**
  - Cada **dimensión** se describe mediante un conjunto de **atributos**.
    - Por ejemplo, la **dimensión Producto** puede constar de cuatro atributos: **nombre, precio, línea de producción y marca**.
  - Los **atributos** pueden estar relacionados mediante una **jerarquía de relaciones**.

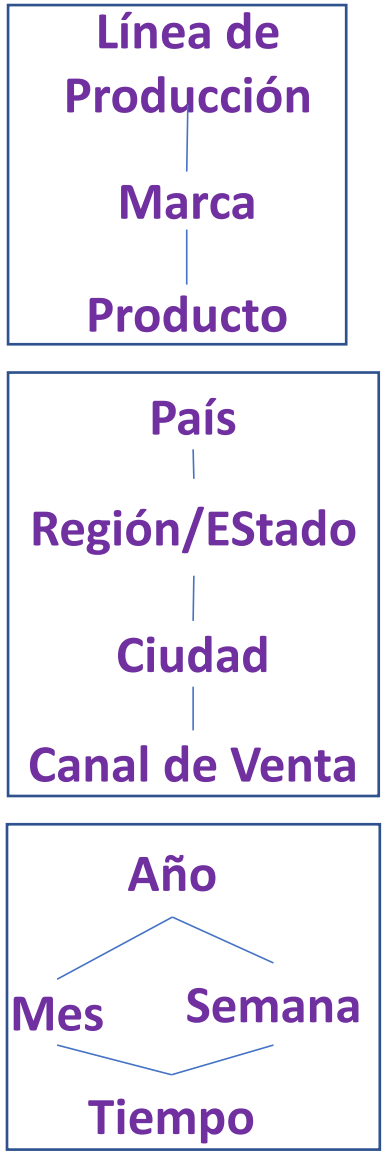

Modelado Multidimensional

- Otra **característica distintiva** del modelo de **cubos de datos** es su énfasis en la **agregación de medidas** por una o más **dimensiones** como una de las operaciones clave;
  - Por ejemplo, **calcular** y **clasificar las ventas totales por canal de venta** (o por **año**).
  - Otras **operaciones populares** incluyen la **comparación de dos medidas** (por ejemplo, **ventas y presupuesto**) **agregadas** por las **mismas dimensiones**.
  - El **tiempo** es una **dimensión de especial** importancia para el apoyo a la toma de decisiones (por ejemplo, análisis de tendencias).
    - A menudo, es conveniente tener conocimientos integrados de calendarios y otros aspectos de la dimensión del tiempo.
- ***Frameworks OLAP* deben facilitar la construcción de CUBOS OLAP**

Operaciones sobre cubos OLAP en la sección "OLAP"

Chaudhuri and Dayal, 1997

Modelado Multidimensional

- **MODELADO LÓGICO**
  - Los **cubos de datos** se pueden modelar mediante diversos **esquemas**, entre ellos:
    - **Esquema en estrella (Star)**: Presenta una **tabla de hechos central** rodeada de **tablas de dimensiones**, con forma de estrella.
    - **Esquema de copo de nieve (Snowflake)**: Amplía el esquema en estrella con **jerarquías dentro de las tablas de dimensiones**.
    - **Esquema de constelación de hechos (Fact Constellation)**: Incorpora **múltiples tablas de hechos** que **comparten** tablas de **dimensiones**, lo que permite relaciones complejas.

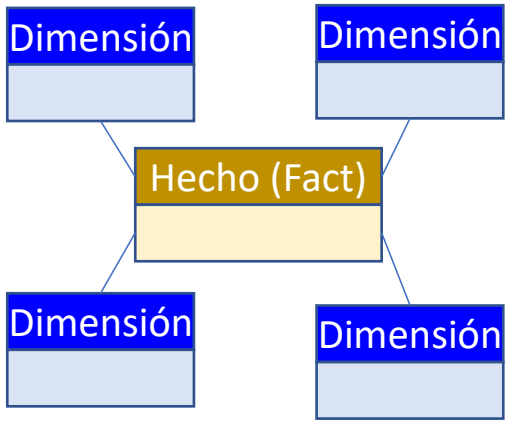

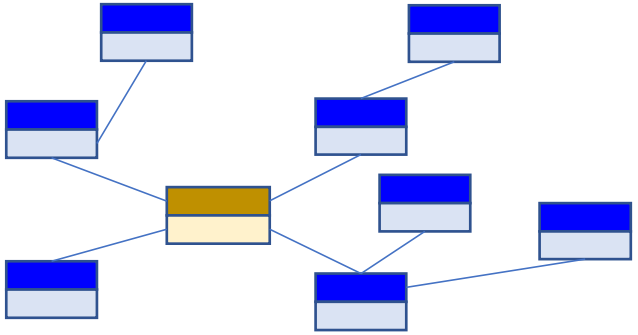

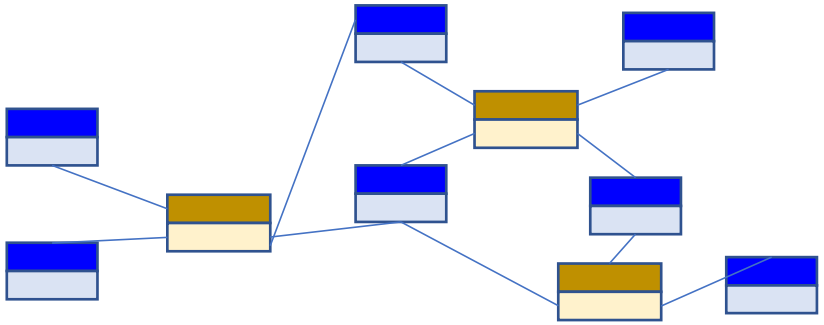

Modelado Multidimensional

- **MODELADO LÓGICO**
  - **Esquema en estrella (Star)**:
    - Un tipo de diagrama **entidad-relación**
    - La **tabla de hechos (*facts*)** contiene los índices y las métricas sobre los eventos de una empresa que se deben registrar de forma continua (el volumen de ventas, por ejemplo).
    - Las **tablas de dimensiones** contienen atributos que describen los datos de la tabla de hechos.
      - Conjunto de datos de referencia para los eventos registrados en la tabla de hechos.
      - Estas **tablas** de **dimensiones están desnormalizadas**, lo que significa que contienen toda la información necesaria sin dividirse en subtablas.

Product	
PK	Product_ID
	Name
	Brand
	Price

Sales	
FK	Product_ID
FK	Sales_Channel_ID
FK	Date_ID
	UnitSold
	Ammount
	Tax

Modelado Multidimensional

- **MODELADO LÓGICO**
  - **Esquema en estrella (Star)**:
    - **Ventajas**:
      - **Menos joins** = mayor rendimiento de las consultas
      - **Fácil** de comprender para las herramientas de **BI** y los analistas
      - Más **sencillo** de **crear** y mantener
    - **Desventajas**:
      - **Redundancia de datos** (p. ej., información de la región duplicada en varias filas)
      - **No escala** bien con **dimensiones grandes** o jerárquicas

Modelado Multidimensional

- **MODELADO LÓGICO**
  - **Esquema de copo de nieve (Snowflake)**
    - Evolución del **esquema estrella.**
    - Las **tablas** de **dimensiones de un esquema en estrella** no están normalizadas, la información referencial en un esquema de **copo de nieve** se almacena según la tercera norma formal (3NF):
      - Los datos se clasifican y ordenan jerárquicamente y la **información redundante se guarda en tablas separadas**.
      - Se crean las **estrellas ramificadas** que recuerdan a la estructura interna de los copos de nieve.

Modelado Multidimensional

- **MODELADO LÓGICO**
  - **Esquema de copo de nieve (Snowflake)**
    - **Ventajas**:
      - **Reduce el almacenamiento** al evitar la **duplicación** de datos
      - Facilita la aplicación de **la integridad de los datos**
      - Mejor **gestión de jerarquías complejas** (p. ej., categorías de productos, geografías)
    - **Desventajas**:
      - Requiere **más joins** en las **consultas**
      - **Latencia de consulta** ligeramente mayor, especialmente en grandes conjuntos de datos
      - Puede resultar más **difícil de navegar** para los usuarios empresariales

Modelado Multidimensional

- **MODELADO LÓGICO**
  - **Esquema de constelación de hechos (Fact Constellation)**:
    - Múltiples tablas de hechos que comparten varias tablas de dimensiones.
    - Ideal para **DWs** grandes o **multidominio.**
    - **Ejemplo:** Un **almacén de datos minorista** puede incluir**:**
      - **Fact_Sales, Fact_Inventory, Fact_Shipments**
    - **Ventajas**:
      - Admite múltiples procesos de negocio en un modelo unificado
      - Dimensiones compartidas que eliminan la duplicación
      - Alta flexibilidad para análisis multifuncional
    - **Desventajas**:
      - Mayor complejidad de modelado
      - Pipelines ETL/ELT más exigentes
      - Mayor complejidad de consultas
      - Posibles desventajas en el rendimiento

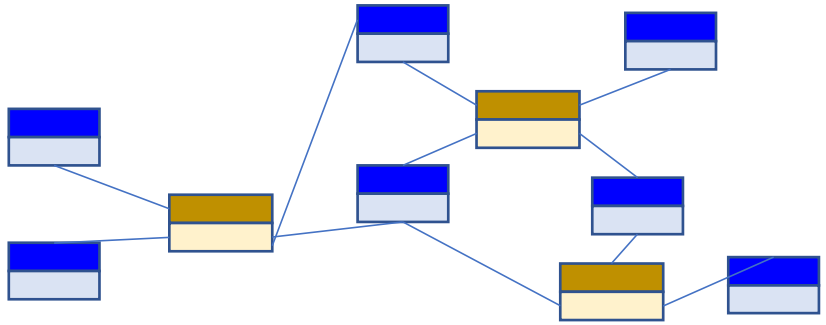

Modelado Multidimensional

- **MODELADO LÓGICO**

Característica	Estrella	Copo de Nieve	Constelación
Normalización	Bajo (desnormalizado)	Medio–Alto	Mixto (compartido + dimensiones normalizadas)
Rendimiento Consultas	Rápido (pocos joins)	Moderada para lento (más joins)	Varia de acuerdo al tamaño de la table de hechos & profundidad de joins
Complejidad	Bajo	Medio	Alto
Uso de Almacenamiento	Alto (redundancia de datos)	Bajo (dimensiones no duplicadas)	Mixto (dimensiones compartidas reduce duplicación)
Flexibilidad del Modelado	Limitado para jerarquías profundas	Modelado Jerárquico Fuerte	Soporte múltiples dominios & granularidades
Casos de Uso	Dashboards, alta concurrencia, ad hoc BI	Datos jerárquicos, Optimización de almacenamiento	Análisis empresarial completo, modelos multiproceso

https://www.exasol.com/hub/data-warehouse/schemas/

Modelado Multidimensional

- **PROCESO DE MODELADO LÓGICO (Kimball bottom-up):**
  - **Paso 1**: Seleccionar el **proceso de negocio** de la organización
    - Hacer **preguntas** sobre un **proceso de negocio**
    - **Ejemplos** de **procesos de negocio**:
      - Facturación y cobranza
      - Supervisión de la calidad del producto
      - Marketing
  - **Paso 2**: Declarar la **granularidad**
    - **Grano** = **nivel** para almacenar la **tabla de hechos**
    - Un **nivel de datos** que **no** se puede **dividir más**
    - **Ejemplos** de procesos de negocio:
      - Servicio de **música** -> Grano de **canción**
      - Servicio de **envío** -> Grano de **item de pedido**

Modelado Multidimensional

- **PROCESO DE MODELADO LÓGICO (Kimball bottom-up):**
  - **Paso 3**: Identificar las **dimensiones**
    - Seleccione las **dimensiones** que correspondan a cada **fila**
    - Preguntar a usuarios y analistas = comentarios valiosos
    - **Ejemplos** de **dimensiones** comunes:
      - **Tiempo**: año, trimestre y mes
      - **Ubicación**: dirección, estado y país
      - **Usuarios**: nombres y correo electrónico
  - **Paso 4**: Identificar los **hechos**
    - **Mediciones** para cada fila de la **tabla de hechos**
    - ¿Qué estamos **<u>respondiendo</u>**?
    - **Ejemplos** de **hechos**:
      - **Servicio de música**: número total de reproducciones, ingresos por ventas de una canción
      - **Servicio de transporte compartido**: distancia de viaje, tiempo necesario

OLAP (Online Analytical Processing)

- *Una empresa vende **tres productos** (seguro de vida, seguro de motor, seguro de salud) en 3 **canales** (tienda online, línea de atención al cliente, comercio en sucursal).*
  - ***Pregunta sencilla**: cuántos **seguros de vida** se **vendieron** durante el último **trimestre** → respuesta consulta base de datos de ventas.*
  - *Pero ¿cuántos **seguros de vida** se vendieron en cada uno de sus canales de venta y comparar los resultados reales con las ventas proyectadas?*
- **Las consultas OLAP complejas degradarían el rendimiento de las transacciones operativas (SQL, NoSQL).**
- ***→ OLAP***

OLAP (Online Analytical Processing)

- **Proceso interactivo de creación, gestión, análisis y generación de informes sobre datos:**
  - **OLAP** es un enfoque para responder rápidamente a **consultas analíticas multidimensionales** (MDA).
  - **OLAP** forma parte de la categoría más amplia de **inteligencia de negocios (BI)**, que también abarca bases de datos relacionales, la generación de informes y la minería de datos.
  - Las **herramientas OLAP** permiten a los **usuarios analizar datos multidimensionales** de forma **interactiva** desde **múltiples perspectivas**.
- **Objetivo**: Soportar **consultas *ad-hoc***, pero **complejas**, realizadas por analistas de negocio:
  - **Exploración** y **agregación** de **datos** de **diversas maneras**
- Soporte a condiciones booleanas complejas, funciones estadísticas y análisis de series temporales

OLAP (Online Analytical Processing)

- **Permite analizar datos mediante vistas complejas y multidimensionales**
  - **→ Cubo de Datos OLAP → Interactivo y Visual → Operaciones OLAP**
  - ***Frameworks*** *OLAP* deben facilitar esta tarea

Sales channel	Product	Time	Ammount
Online Shop	Life Insurance	2016	5
Online Shop	Motor Insurance	2016	15
Online Shop	Health Insurance	2016	10
Customer Hotline	Life Insurance	2016	10
Customer Hotline	Motor Insurance	2016	5
Customer Hotline	Health Insurance	2016	20
Branch Trade	Life Insurance	2016	15
Branch Trade	Motor Insurance	2016	10
Branch Trade	Health Insurance	2016	15
…			

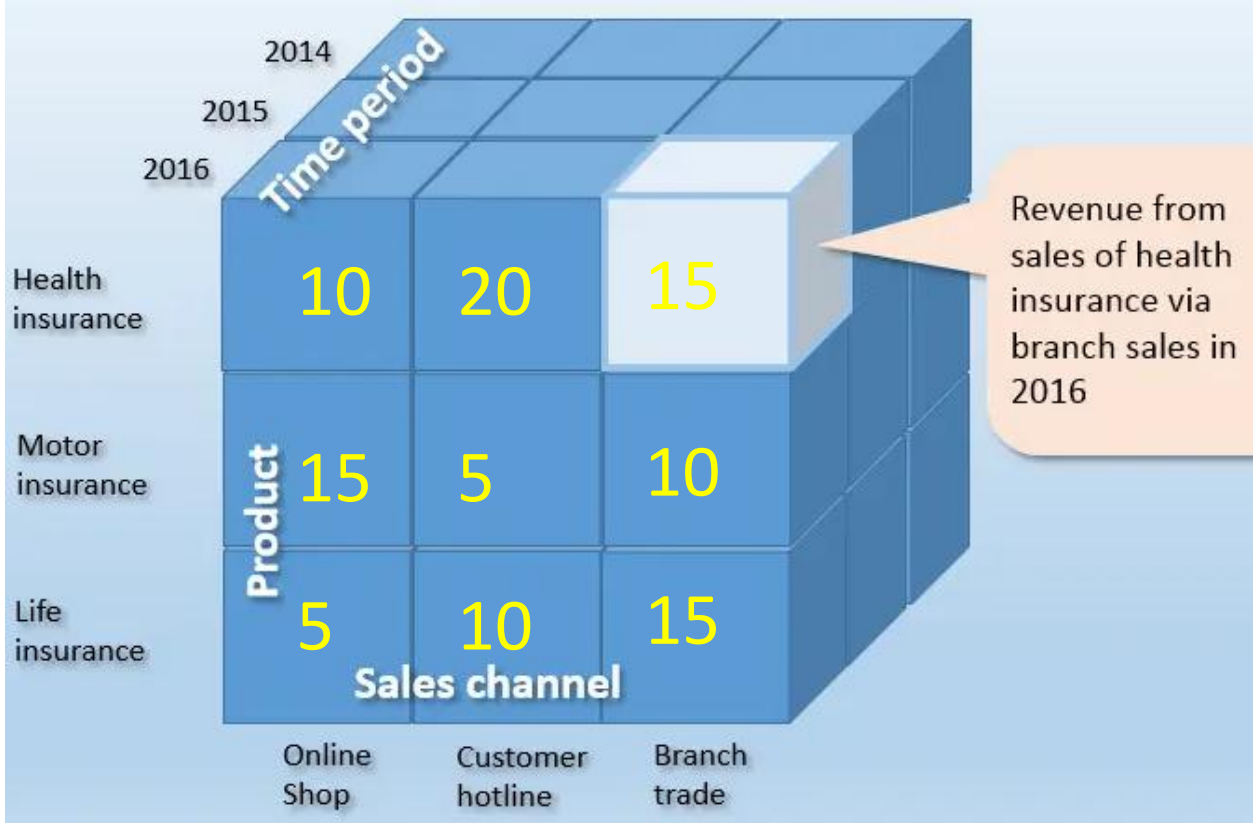

OLAP (Online Analytical Processing)

- **Consultas OLAP típicas:**
  - Escriba un ***JOIN*** **multitabla** para comparar las **ventas** de cada **producto** en lo que va del **año** (YTD) con las del **año anterior**.
  - Repita el proceso anterior para encontrar los **5 productos** que más contribuyen al **margen**.
  - Repita el proceso anterior para encontrar las **ventas** de **productos** a **clientes nuevos y existentes**.
  - Repita el proceso anterior para encontrar los **clientes** con un **crecimiento de ventas negativo**.

OLAP (Online Analytical Processing)

- Los sistemas **OLAP** se dividen en **tres tipos principales**:
  - **ROLAP (OLAP relacional):** Este sistema utiliza una base de **datos relacional para almacenar datos multidimensionales** para su análisis. Crea **vistas** o **tablas** en la base de datos según las necesidades de la aplicación. No todas las consultas SQL deben almacenarse como **vistas**; solo se definen como tales aquellas de uso frecuente y con un alto consumo computacional.
  - **MOLAP (OLAP multidimensional)**: En MOLAP, los datos multidimensionales se **almacenan físicamente como una matriz**, formando una **estructura de cubo**. Los valores de las dimensiones se convierten en subíndices de la matriz y los **datos de resumen** se almacenan en las **celdas de la matriz**.
  - **HOLAP (OLAP híbrido):** HOLAP combina las características de ROLAP y MOLAP. Dado que cada uno tiene sus ventajas y desventajas, HOLAP está diseñado para aprovechar las ventajas de ambos sistemas.

OLAP (Online Analytical Processing)

- **Operaciones**:
  - **Slicing**: proporciona **partes de un cubo** a lo largo de **una dimensión**
  - **Dicing**: proporciona un **subcubo** seleccionando **una o más dimensiones**
  - **Rotating/Pivoting**: visualiza los **datos** desde una **nueva perspectiva**
  - **Roll-up**: proporciona un **mayor nivel de generalización**
  - **Drill-down**: proporciona un **mayor nivel de detalle**

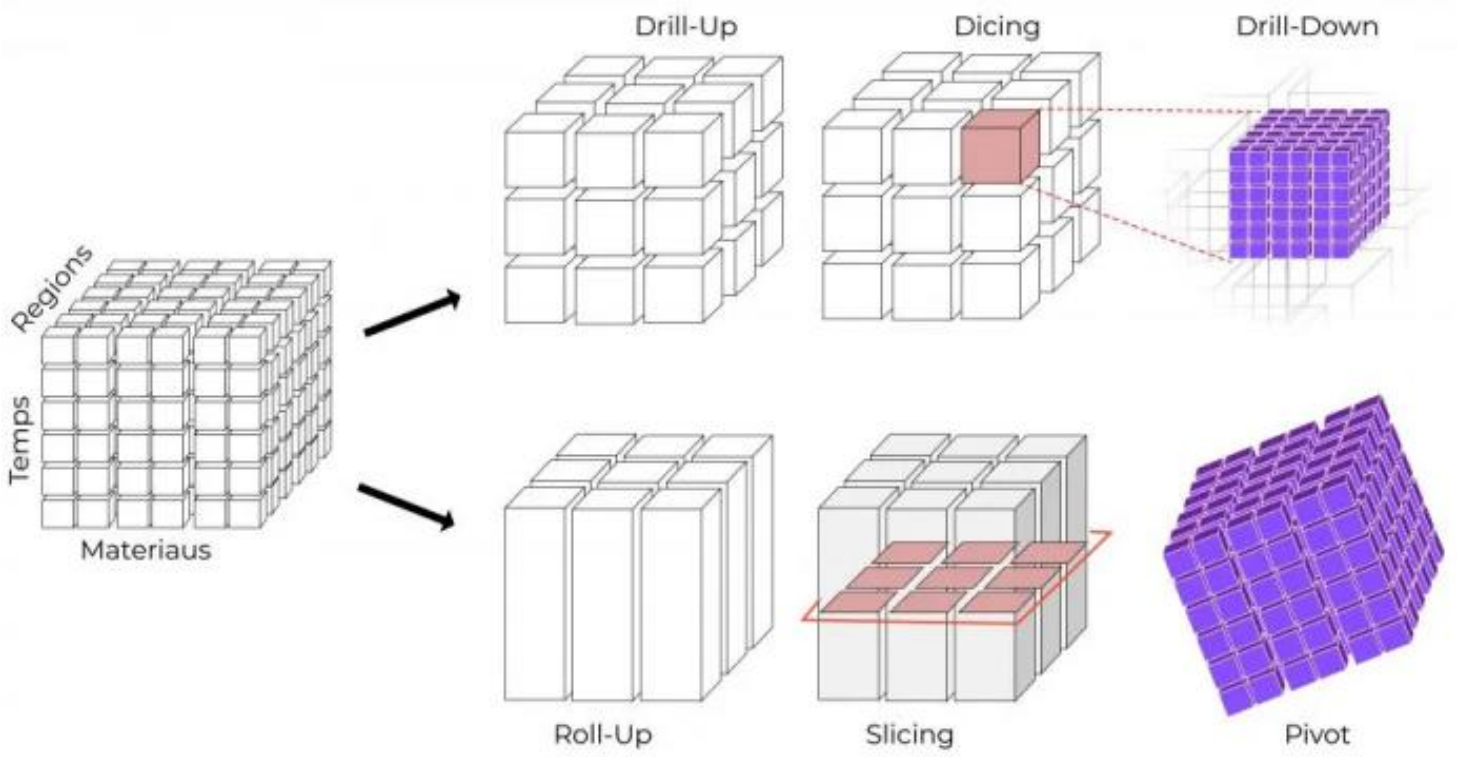

Pivoting

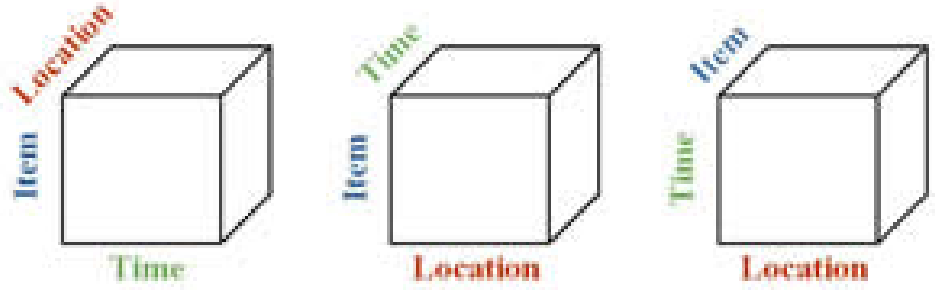

https://kyligence.io/blog/blog-what-is-olap/

OLAP (Online Analytical Processing)

- **Operaciones**:
  - ***Slice***: Proporciona partes de un cubo a lo largo de **una dimensión**.
    - **Selecciona** "**una dimensión**" del **cubo**, lo que genera un **subcubo**.
    - **Reduce** la dimensionalidad del cubo.
    - **Establece** una o más dimensiones con valores específicos y conserva un subconjunto de dimensiones para los valores seleccionados.
    - **Filtra** los datos.
    - En esta imagen se ha aislado la porción "**2015**" de la dimensión "**Tiempo**", de modo que muestra todas las **ventas** que se han generado en **2015** en **todos los canales**.

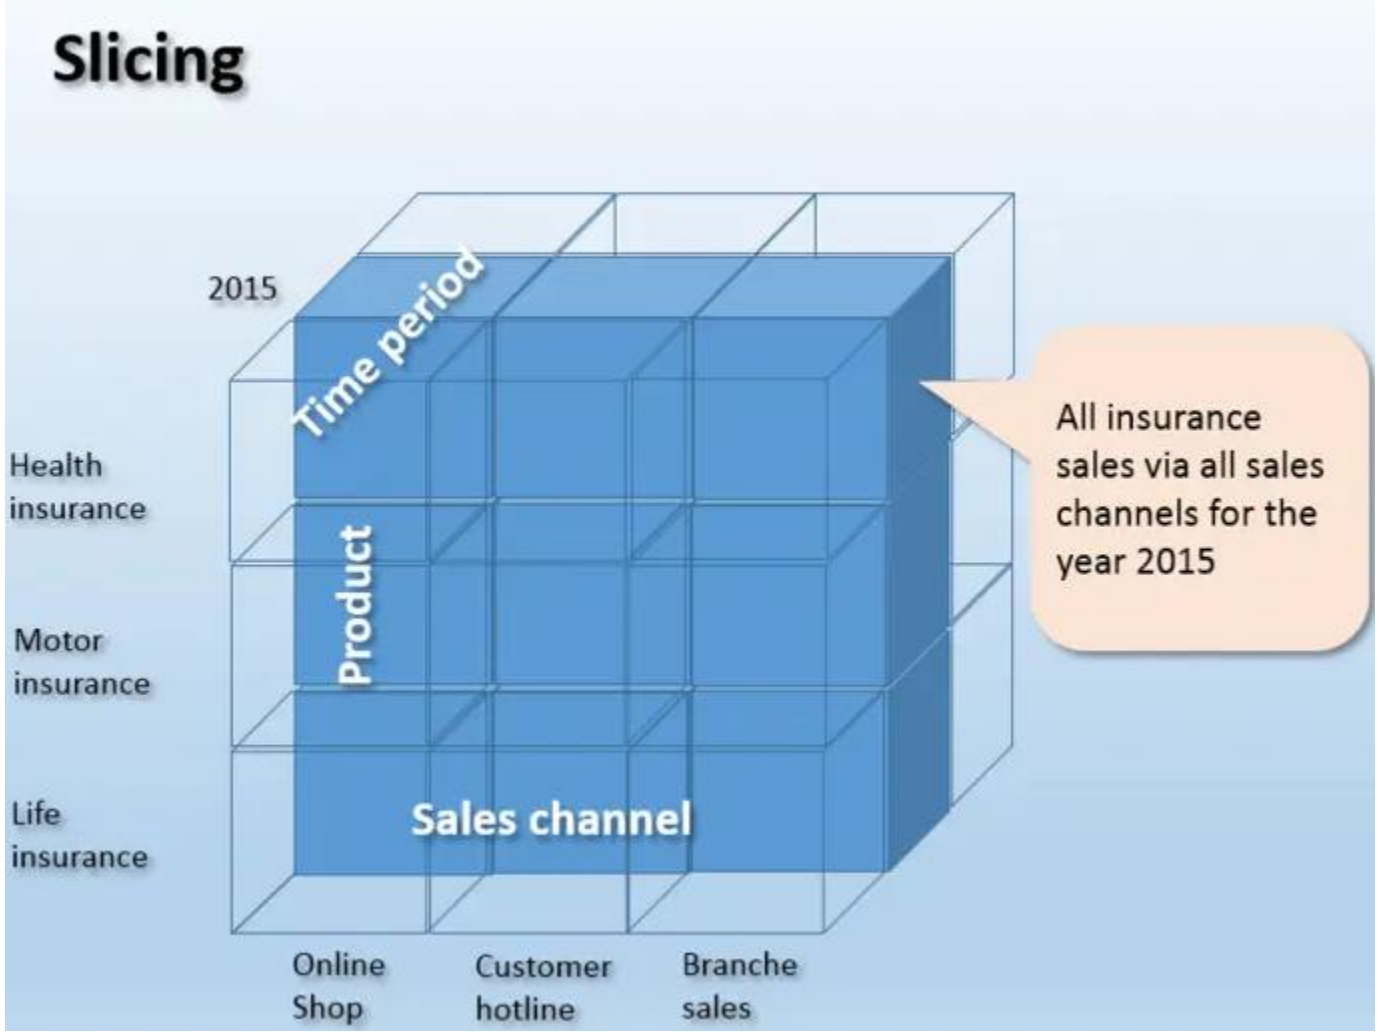

OLAP (Online Analytical Processing)

- **Operaciones**:
  - ***Dice***: **Define** un **subcubo** seleccionando **"una o más dimensiones".**
    - Se refiere a la condición de **selección** de rango en una o más dimensiones.
    - **Reduce** el número de valores miembro de una o más dimensiones.
    - En esta imagen muestra una operación de **dicing** en la cual el **cubo tridimensional** se **reduce** en tres dimensiones a **una porción de información.**

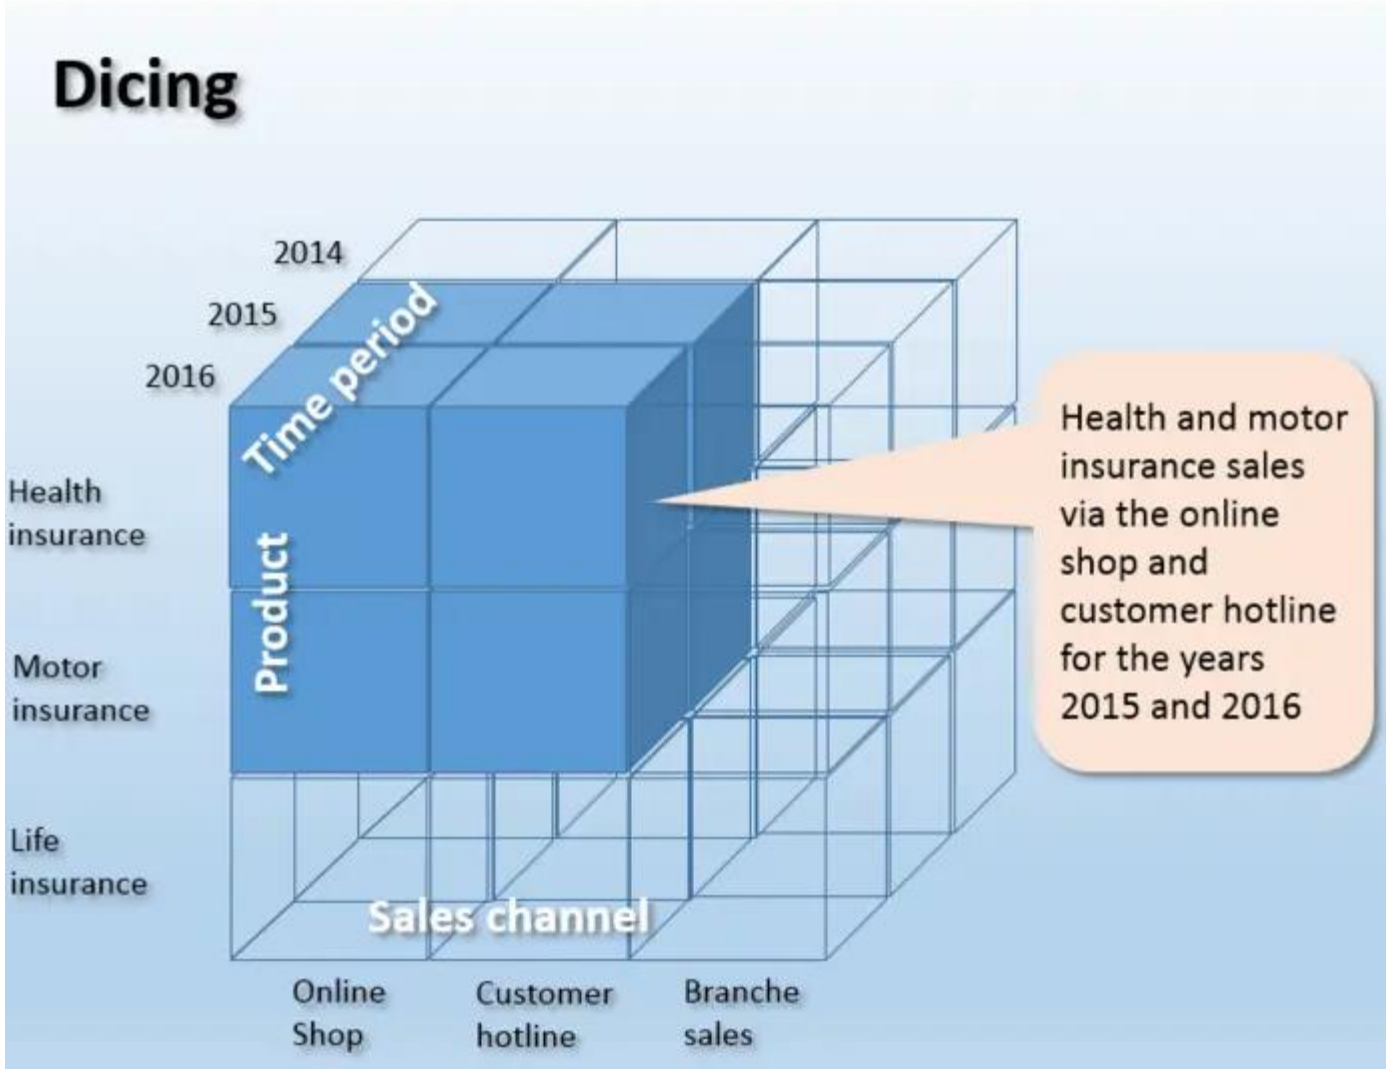

OLAP (Online Analytical Processing)

- **Operaciones**:
  - ***Rotate/Pivote***: Visualiza los datos desde una **nueva perspectiva**.
    - **Selecciona** una **dimensión** (orientación) diferente como **enfoque** para el análisis.
    - **Gira** el eje de datos para verlos desde diferentes perspectivas.
    - **Agrupa** datos con diferentes dimensiones.
    - En esta imagen se ha girado el cubo para que la dimensión "**Tiempo**" sea visible (foco).

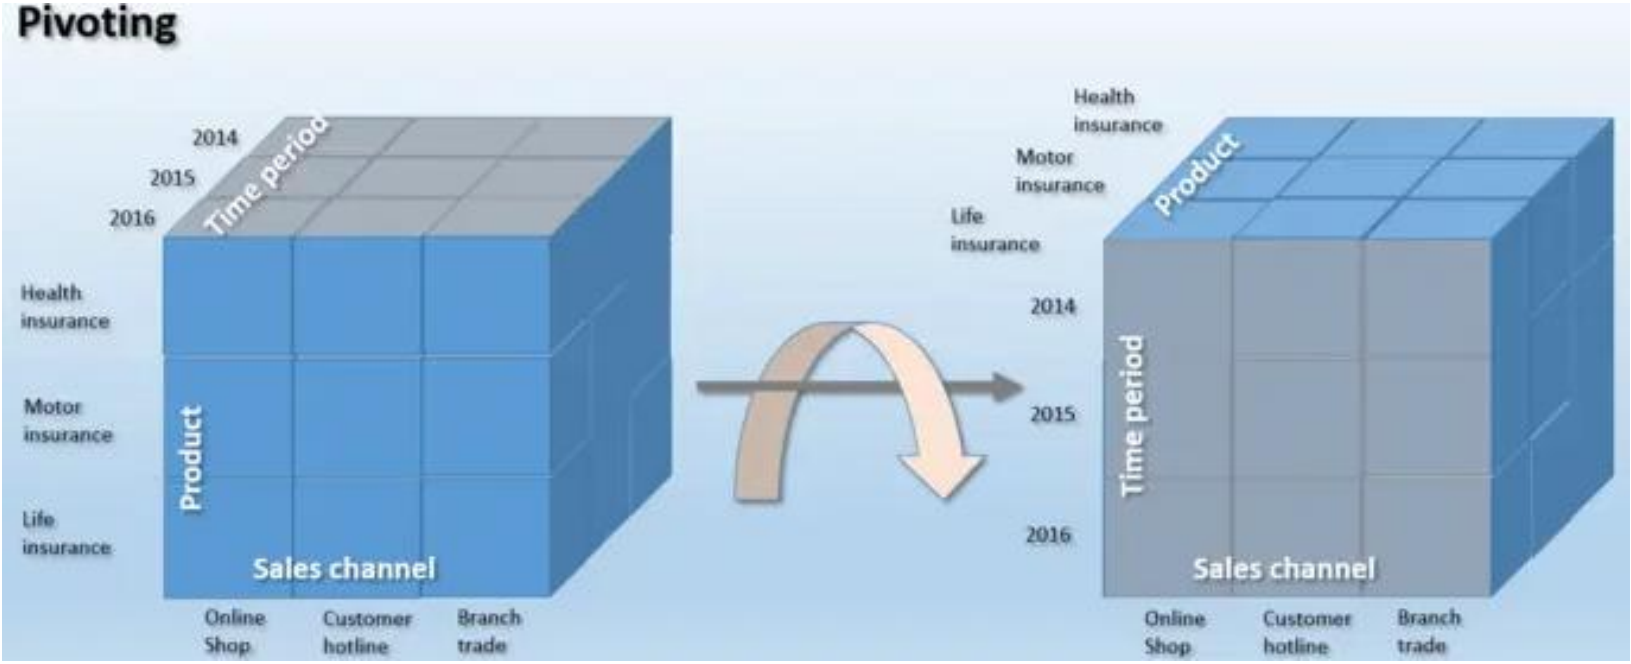

OLAP (Online Analytical Processing)

- **Operaciones**:
  - ***Roll-Up:*** Proporciona un mayor nivel de **generalización**
    - **Agrupación** específica en una dimensión donde pasamos de un nivel de agregación más bajo a uno más **alto**.
    - **Ejemplo**:
      - resumen de **ventas** por **mes,** por **año** y luego **todo el tiempo**.
      - resumen sobre la **jerarquía** de agregados (**ventas totales** por canal de venta, todos los canales).
    - **Agregaciones** gradualmente más **gruesas**.
      - Puede incluir múltiples dimensiones.
      - **Ejemplo**: agrupar los datos de **ventas** (ya agregados por **canal**) además por **producto**.

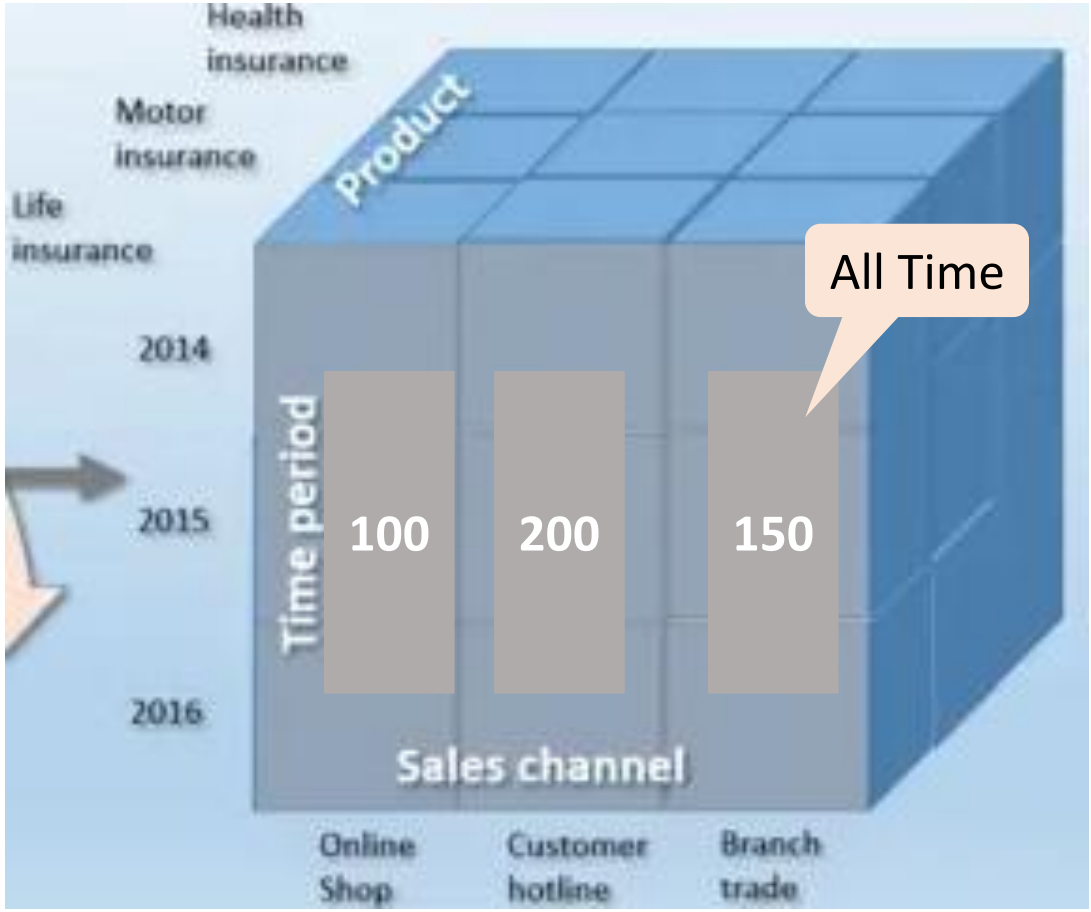

OLAP (Online Analytical Processing)

- **Operaciones**:
  - ***Drill-Down:*** Proporciona un mayor nivel de **detalle**
    - Visión más detallada de los datos **agregados –** va de mayor a menor nivel de agregación.
    - Inverso de ***Roll-Up***.
    - ***drill-down*** del objeto "**Ventas**" en la dimensión "**Productos**". Al ampliar el **detalle**, las **cifras de ventas** pueden interpretarse en relación con cada **producto en particular**.

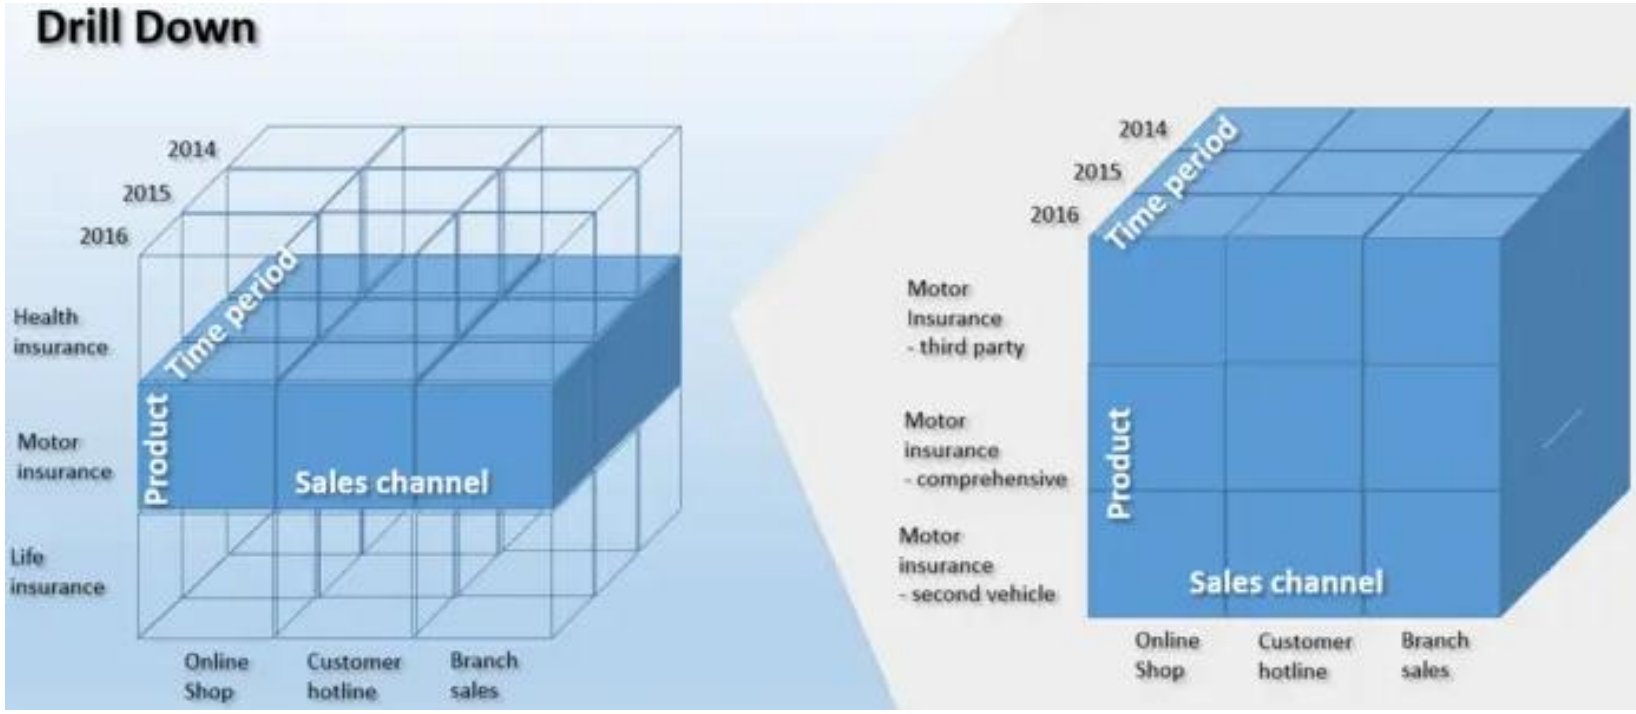

OLAP (Online Analytical Processing)

- **Operaciones**:
  - **¿Podemos realizar operaciones *OLAP* en *SQL*?**
  - **→ NECESITAREMOS MUCHAS CONSULTAS Y SUB-CONSULTAS**
  - **Recuerde:**
    - **GROUP BY, Funciones de agregación**

```sql
SELECT column1, column2, aggregate_function(column3) AS alias_name
FROM table_name
WHERE condition -- Filters individual rows before grouping
GROUP BY column1, column2 -- Groups rows with the same values
HAVING aggregate_condition -- Filters groups after aggregation
ORDER BY column1 DESC; -- Sorts the final result set
```

OLAP (Online Analytical Processing)

- **Operaciones**:
  - *Consultas OLAP* en *SQL*

OLAP (Online Analytical Processing)

- **Operaciones**:
  - **Roll-up en SQL**
    - **Por ejemplo, encontrar las ventas totales de cada producto en cada ciudad.**

```
SELECT r.City, s.Product_ID, SUM(s.Ammount) AS alias_name INTO City_Sales
FROM Sales s, Region r
WHERE s.Region_ID = r.Region_ID
GROUP BY r.City, s.Product_ID;
```

    - **Resultado: r.City puede presentar duplicidad**

```
SELECT r.City, c.Product_ID, SUM(c.Ammount)
FROM City_Sales c, Region r
WHERE c.City = r.City
GROUP BY r.City, c.Product_ID;
```

OLAP (Online Analytical Processing)

- **Operaciones**:
  - **Slicing en SQL**
    - **Por ejemplo, Dividir el cubo de datos en la dimensión temporal, por ejemplo, elegir ventas solo en el año 2016.**

```
SELECT s.*
FROM Sales s, Date d
WHERE s.Date_ID = d.Date_ID AND d.Year = 2016
```

  - **Dicing en SQL**
    - **Por ejemplo, división de ventas en la dimensión temporal: ventas totales de cada producto en cada año.**

```
SELECT s.Product_ID, D.Year, SUM(s.Ammount)
FROM Sales s, Date d
WHERE s.Date_ID = d.Date_ID
GROUP BY d.Year, s.Product_ID;
```

OLAP (Online Analytical Processing)

- **Operaciones**:
  - **Pivoting, slicing y dicing en SQL**
    - **Segmentar las dimensiones de tiempo (año = 2016) y canal de venta (= “Online Shop”), y luego pivotar a Product_ID y Mes (en la dimensión de tiempo).**

```
SELECT s.Product_ID, D.Month, SUM(s.Ammount)
FROM Sales s, Date d, Sales_Channel sc
WHERE s.Date_ID = d.Date_ID
      AND d.Year = 2016
      AND sc.Name = “Online Shop”
GROUP BY s.Product_ID, d.Month;
```

    - **Problemas**:
      - Se necesitan otras consultas para obtener los (sub)totales por producto en el 2016.
      - Se necesita otra consulta para obtener el importe total de “Online Shop” en el 2016.
      - Se necesitan otras consultas para obtener los (sub)totales de otros canales de ventas.

OLAP (Online Analytical Processing)

- **Operaciones**:
  - Familia **extendida** de funciones de **agregación**
    - **RANK, DENSE RANK, PERCENTILE, NTILE, LIMIT** etc.
    - Consultas **WINDOW** ("ventana de filas alrededor de cada tupla")
  - Opciones adicionales en la cláusula **GROUP BY** (de SQL:1999):
    - **GROUPING SETS**
    - **ROLLUP**
    - **CUBE**

OLAP (Online Analytical Processing)

- **Operaciones**:
  - Familia **extendida** de funciones de **agregación**
    - **RANK y DENSE RANK** son funciones de ventana en SQL para **clasificar filas**
    - **RANK:** Asigna un **rango** a cada **fila** en un conjunto de resultados. Si **dos o más filas empatan**, cada una recibe el **mismo rango**, pero **deja huecos** en la secuencia numérica siguiente **(ej. 1, 2, 2, 4).**
    - **DENSE RANK:** Asigna un **rango** a cada **fila**. Si hay **empates**, reciben el **mismo rango**, pero no deja huecos en la secuencia numérica **(ej. 1, 2, 2, 3)**

```sql
SELECT pais, ciudad, total_ventas,
 RANK() OVER (PARTITION BY pais
 ORDER BY total_ventas DESC) as
 ranking_ciudad
FROM ventas
);
```

```sql
SELECT pais, ciudad, total_ventas,
 DENSE_RANK() OVER (PARTITION
 BY pais ORDER BY total_ventas
 DESC) as ranking_ciudad
FROM ventas
);
```

OLAP (Online Analytical Processing)

- **Operaciones**:
  - Opciones adicionales en la cláusula **GROUP BY** (de SQL:1999):
    - **GROUPING SETS, ROLLUP y CUBE** son **extensiones GROUP BY** en **SQL** que permiten generar **múltiples niveles de agregación** (subtotales y totales generales) en **una sola consulta**, evitando el uso de **múltiples UNION ALL.**

Característica	GROUPING SETS	ROLLUP	CUBE
Enfoque	Selectivo / Manual	Jerárquico (Top-down	Exhaustivo (Todas las vías)
Resultado	Solo lo especificado	Subtotales por nivel	Todas las permutaciones
Uso común	Reportes personalizados	Tiempo, geografía	Análisis de datos (OLAP)

- **ROLLUP vs. CUBE**: **ROLLUP** genera **subtotales jerárquicos (menos filas),** mientras que **CUBE** genera **todas las combinaciones** posibles de **subtotales**.
- Uso de **NULL**: Los **valores NULL** en las **columnas agrupadas** indican que la **fila corresponde a un subtotal o total general**.

https://www.ibm.com/docs/es/db2/12.1.x?topic=clause-examples-grouping-sets-cube-rollup

OLAP (Online Analytical Processing)

- **Operaciones**:
  - Opciones adicionales en la cláusula **GROUP BY** (de SQL:1999):
    - **GROUPING SETS:** Especifica **exactamente qué combinaciones de columnas agrupar**.
      - Solo calcula los **grupos** definidos **explícitamente**.
      - **Ejemplo**: **GROUPING SETS ((ciudad), (pais), ())** generará
        - **subtotales** por **ciudad**,
        - subtotales por **país** y
        - el **total general**.

```
SELECT pais, ciudad, SUM(monto) AS total_ventas
FROM ventas
GROUP BY GROUPING SETS (
 (pais), -- Subtotal por país
 (ciudad), -- Subtotal por ciudad
 () -- Total General
);
```

OLAP (Online Analytical Processing)

- **Operaciones**:
  - Opciones adicionales en la cláusula **GROUP BY** (de SQL:1999):
    - **ROLLUP:** Crear **agregaciones jerárquicas**.
      - Ideal para **datos** que tienen **una relación de dependencia** (como **Año > Mes > Día**)
      - Crea **grupos reduciendo** la lista de **columnas de derecha a izquierda**.
      - **Ejemplo**: **ROLLUP (pais, ciudad)** generará:
        - (pais, ciudad) - Detalle por ciudad.
        - (pais) - Subtotal por país.
        - () - Total general.

```
SELECT pais, ciudad, SUM(monto) AS
total_ventas
FROM ventas
GROUP BY ROLLUP(pais, ciudad);
```

OLAP (Online Analytical Processing)

- **Operaciones**:
  - Opciones adicionales en la cláusula **GROUP BY** (de SQL:1999):
    - **CUBE:** Genera **todas las combinaciones posibles de las columnas especificadas**.
      - Es la herramienta más **exhaustiva para análisis multidimensional**.
      - Si tienes ***n*** columnas, generará 2^n **combinaciones de agrupamiento**.
      - **Ejemplo**: **CUBE (pais, producto)** generará:
        - (pais, producto)
        - (pais)
        - (producto)
        - () - Total general

```
SELECT pais, ciudad, SUM(monto) AS
total_ventas
FROM ventas
GROUP BY CUBE (pais, ciudad);
```

ETL

Próxima clase: “Pipelines de Datos - ETL”

Conclusión

- **DW**: almacena **indicadores clave de rendimiento** (**KPIs** – **medidas**) y su **contexto** (**dimensiones**).
  - Las **medidas** se **preagregan** en varios **niveles**.
  - Las **dimensiones** explican el **contexto** de los **datos**.
- El **cubo de datos** procesado se pone a disposición de los analistas de negocios, quienes pueden **explorar los datos** mediante diversas herramientas de visualización, lo que **facilita el procesamiento y la consulta analítica e interactiva ad hoc**.

REFERENCIAS

Bibliografía

- Lake P., and Crowther, P. (2013). **Concise Guide to Databases: A Practical Introduction (1th edition).**
- Kleppmann, M. (2017). **Designing Data Intensive Applications.** O'Reilly.
- Inmon, W. H. (2005). **Building the data warehouse**. John wiley & sons.
- Russo, M., & Ferrar, A. (2017). **Analyzing data with Microsoft Power BI and Power Pivot for Excel**. Microsoft.
- Jafari, R. (2022). **Hands-On Data Preprocessing in Python: Learn how to effectively prepare data for successful data analytics**. Packt Publishing Ltd.
- Sartaj Singh. **Data Warehousing an Data Mining**. Lovely Professional University. Phagwara. https://ebooks.lpude.in/computer_application/mca/term_5/DCAP603_DATAWARE_HOUSING_AND_DATAMINING.pdf
- Gamazo, A. **Introducción al Data Warehouse**. Universitat Oberta de Catalunya. https://openaccess.uoc.edu/server/api/core/bitstreams/100c2023-5336-4ca3-aa7d-f28df9c3937a/content
- Chaudhuri, S., & Dayal, U. (1997). **An overview of data warehousing and OLAP technology**. ACM Sigmod record, 26(1), 65-74. https://www.microsoft.com/en-us/research/wp-content/uploads/2016/02/sigrecord.pdf

REFERENCIAS

Recursos

- Goran Nenadic. **Data Integration and Analysis (COMP33111).** University of Manchester. https://personalpages.manchester.ac.uk/staff/gnenadic/
- Christian S. Jensen, Torben Bach Pedersen, Christian Thomsen. Université libre de Bruxelles (ULB). **Introduction to Data Warehousing and Business Intelligence**. https://cs.ulb.ac.be/public/_media/teaching/infoh415/dwnotes.pdf
- NRI INSTITUTE OF TECHNOLOGY. **DATAWAREHOUSE INTRODUCTION**. https://nriit.edu.in/files/IT-Notes/DWDM/UNIT-1(1).pdf
- Aaren Stubberfield. **DATA WAREHOUSING CONCEPTS**. https://projector-video-pdf-converter.datacamp.com/29835/chapter1.pdf
- PEOPLE'S UNIVERSITY. **UNIT 2 DATA WAREHOUSE ARCHITECTURE**. https://egyankosh.ac.in/bitstream/123456789/81153/3/Unit-2.pdf
  - https://notes4learners.blogspot.com/p/dwdm-unit-2.html
- Janet Delve. School of Creative Technologies. **INTRODUCTION TO DATA WAREHOUSING AND BIG DATA**. https://www.eark-project.com/resources/conference-presentations/dpc-eark-event/22-dpcdelvedatamining/Delve-Data%20Warehousing.pdf_%3B%20filename_%3DUTF-8%27%27Delve-Data%2520Warehousing.pdf
- TECNOLOGIABI. **¿Cómo implementar un Data Warehouse?** https://tecnologiabi.com/como-implementar-un-data-warehouse/
- EXASOL. **Building a Data Warehouse in 2025+**. https://www.exasol.com/hub/data-warehouse/building-create/
- EXASOL. **DWH Concepts: Basics & Hands-On Tutorial**. https://www.exasol.com/hub/data-warehouse/concepts-basics/
- IONOS**. Los data warehouses y la toma de decisiones en la empresa. Disponible en: https://www.ionos.mx/digitalguide/online-marketing/analisis-web/los-data-warehouses-en-la-business-intelligence/**